

HYDRAS — Report FCM

Field Climbing Method come Baseline di Confronto con RL

1 Motivazione

Per valutare il contributo dell'apprendimento per rinforzo nel problema di source seeking, è stato implementato e testato il **Field Climbing Method** (FCM) come baseline algoritmica. FCM rappresenta l'approccio gradient-based classico al problema: stima il gradiente del campo di concentrazione a partire dalle letture locali dei sensori e si muove nella direzione di salita più ripida. A differenza del modello RL, non richiede training e non mantiene memoria globale dell'episodio: decide l'azione ad ogni step basandosi esclusivamente sulle osservazioni correnti.

2 Algoritmo Field Climbing Method

2.1 Stima del Gradiente per Minimi Quadrati

L'agente legge la concentrazione in **9 punti**: la posizione corrente $\mathbf{p}$ (concentrazione centrale C_0) e gli 8 sensori direzionali che campionano $C(\mathbf{p} + \boldsymbol{\delta}_i)$ con offset $\boldsymbol{\delta}_i = \hat{d}_i \cdot r_s$, dove $\hat{d}_i$ è il versore della direzione i e r_s il *sensor range*.

Assumendo un'approssimazione lineare locale del campo (Taylor al primo ordine):

$$C(\mathbf{p} + \boldsymbol{\delta}_i) \approx C(\mathbf{p}) + \nabla C \cdot \boldsymbol{\delta}_i \quad (1)$$

Il punto centrale funge da riferimento: sottraendo C_0 da ciascuna lettura e normalizzando per r_s si ottiene un sistema sovradeterminato 8×2 :

$$\mathbf{D} \nabla C = \mathbf{b} \quad \mathbf{D} \in R^{8 \times 2}, \quad b_i = \frac{C_i - C_0}{r_s} \quad (2)$$

risolto per minimi quadrati con `numpy.linalg.lstsq`. Il punto centrale ancora il piano a C_0 in $(0, 0)$; gli 8 sensori determinano congiuntamente la direzione e la magnitudine del gradiente.

2.2 Selezione dell'Azione

Le 8 azioni discrete corrispondono alle direzioni cardinali e diagonali (N, S, E, O, NE, SE, NO, SO); ogni direzione ha passo fisso pari a $v_{\max} \cdot \Delta t = 1 \text{ m/s} \times 10 \text{ s} = 10 \text{ m}$.

La direzione scelta massimizza la proiezione del gradiente stimato:

$$a^* = \arg \max_i \hat{d}_i \cdot \nabla C \quad (3)$$

Se il gradiente stimato è inferiore a 10^{-12} in norma (campo localmente piatto), l'azione viene scelta uniformemente a caso tra le direzioni non mascherate.

2.3 Action Masking

Per impedire collisioni con la costa, le azioni che porterebbero l'agente fuori dal dominio vengono mascherate prima della selezione, sia nel caso gradient-based che in quello random.

3 Dataset e Ambiente di Simulazione

Il setup sperimentale è identico a quello usato per il modello RL. Il dataset è composto da simulazioni MIKE21 su un dominio marino di $3 \times 2,5$ km (baia di Cecina, UTM32N), risoluzione 10 m, passo temporale 10 s, con 132 sorgenti $\times$ 4 scenari vento (V0–V3).

- **Sorgenti di inferenza:** SRC107–SRC132 (26 sorgenti)
- **Chunk temporali:** Q1/4, Q1/2, Q3/4
- **Episodi per scenario:** 2
- **Totale episodi per run:** $26 \times 4 \times 3 \times 2 = 624$
- **Durata massima episodio:** 1080 step (= 3 h simulate)
- **Soglia di successo:** distanza dalla sorgente ≤ 50 m
- **Distanza iniziale media:** ≈ 800 m

4 Sweep del Sensor Range

Il parametro critico di FCM è il **sensor range** r_s : la distanza a cui vengono campionati i sensori direzionali. Un range troppo piccolo rende i sensori insensibili al gradiente (differenze di concentrazione trascurabili su scala locale); un range troppo grande campiona zone distanti dalla posizione corrente, riducendo la validità dell'approssimazione lineare e aumentando il tempo medio di convergenza verso la sorgente.

Sono stati testati cinque valori: $r_s \in \{20, 50, 100, 150, 200\}$ m, con 2 episodi per scenario (624 episodi totali per run).

r_s	SR globale	Step medi (succ.)	V0	V1	V2	V3
20 m	19,4%	274,5 ($\sim 45,7$ min)	17,9%	10,3%	19,2%	30,1%
50 m	32,9%	182,7 ($\sim 30,5$ min)	39,7%	16,0%	23,7%	51,9%
100 m	18,8%	411,6 ($\sim 68,6$ min)	28,2%	8,3%	16,0%	22,4%
150 m	13,6%	546,4 ($\sim 91,1$ min)	16,0%	5,1%	12,2%	21,2%
200 m	13,8%	398,7 ($\sim 66,4$ min)	6,4%	6,4%	13,5%	28,8%

Tabella 1: Risultati dello sweep su sensor range. In verde il valore ottimale ($r_s = 50$ m).



Il valore ottimale risulta $r_s = 50$ m, con un success rate globale del **32,9%** e un tempo medio al successo di ~ 30 minuti. Per valori superiori il success rate crolla significativamente rispetto al valore ottimale, e il tempo medio al successo aumenta, a causa dell'approssimazione lineare sempre meno valida su scale spaziali grandi rispetto alla struttura del plume.

r_s	Q1/4	Q1/2	Q3/4
20 m	41,3%	1,0%	15,9%
50 m	50,5%	11,5%	36,5%
100 m	28,8%	1,4%	26,0%
150 m	16,8%	1,0%	23,1%
200 m	11,1%	7,7%	22,6%

Tabella 2: Success rate per chunk temporale al variare del sensor range.

5 Analisi dei Risultati — $r_s = 50$ m

I grafici seguenti analizzano il comportamento di FCM con il sensor range ottimale su 624 episodi.

Figura 1: Distribuzione delle distanze iniziali di spawn — FCM $r_s = 50$ m.Figura 2: Success rate per scenario di vento e chunk temporale — FCM $r_s = 50$ m.




Figura 3: Distribuzione del tempo al successo — FCM $r_s = 50$ m.




Figura 4: Distanza media dalla sorgente nel tempo — FCM $r_s = 50$ m.

5.1 Casi rappresentativi

Episodi di successo




Figura 5: Successo — SRC123, V0, Q1/2: convergenza in 137 step (~ 23 min) da 640 m. Gradiente ben definito lungo tutto l'episodio; risalita direzionale del plume.




Figura 6: Successo — SRC118, V0, Q3/4: convergenza in 252 step (~ 42 min) da 651 m. Alcune deviazioni intermedie ma tendenza direzionale sostenuta verso la sorgente.

Episodi di fallimento




Figura 7: Plume sparso — SRC109, V1, Q1/2: l'agente finisce a 2532 m (partenza 2004 m). Il plume diffuso annulla il gradiente locale: l'agente degenera in random walk e nei video appare quasi fermo per tutta la durata dell'episodio.




Figura 8: Massimo locale — SRC127, V2, Q3/4: l'agente percorre 886 m verso la sorgente (da 1008 m a 122 m) ma si blocca su un picco locale di concentrazione e non riesce a uscirne fino al timeout.

6 Confronto FCM vs. RL

Metrica	FCM ($r_s=50$ m)	RL (MaskablePPO)
SR globale	32,9%	96,9% (+64,0%)
Step medi (succ.)	182,7 ($\sim 30,5$ min)	129,2 ($\sim 21,5$ min)
V0	39,7%	100,0% (+60,3%)
V1	16,0%	99,0% (+83,0%)
V2	23,7%	88,7% (+65,0%)
V3	51,9%	99,7% (+47,8%)
Q1/4	50,5%	100,0% (+49,5%)
Q1/2	11,5%	93,5% (+82,0%)
Q3/4	36,5%	97,1% (+60,6%)

Tabella 3: Confronto diretto FCM ottimale vs. modello RL (ppo_20260516_143937, 1560 episodi). Stesse sorgenti di test, stesso ambiente, stessa soglia di successo.

7 Conclusioni e Limiti di FCM

7.1 Limiti strutturali e casi critici

Il Field Climbing Method è un metodo **puramente locale e reattivo**: non mantiene memoria dell’episodio, non sfrutta informazioni di vento e corrente, e non ha mai visto esempi di traiettorie di successo. Questo comporta due categorie di fallimento sistematico:

1. **Campo localmente piatto.** In zone lontane dalla sorgente, o in scenari di vento debole (V1), il plume è così diffuso che tutti i sensori restituiscono concentrazioni quasi identiche. Il gradiente stimato è nullo o dominato dal rumore: l’agente degenera in un random walk e nei video appare sostanzialmente fermo (micro-oscillazioni di ± 10 m su scala di centinaia di metri). V1 è il caso più critico: success rate del 16,0% contro il 99,0% del modello RL (+83pp), confermando che il plume diffuso non è un problema di parametrizzazione del sensor range ma una limitazione intrinseca dell’approccio gradient-based.
2. **Gradiente locale ingannevole.** In un ambiente costiero con correnti complesse, la struttura del plume può presentare massimi locali di concentrazione distanti dalla sorgente reale. FCM segue il gradiente locale senza meccanismi di esplorazione forzata: viene attratto da questi massimi locali e si blocca. Il chunk Q1/2 registra le performance peggiori per tutti i sensor range (11,5% nel caso migliore), suggerendo che il campo a metà simulazione abbia una struttura di plume più complessa o meno direzionata.

7.2 Conclusione

Il gap di 64 punti percentuali tra FCM (32,9%) e RL (96,9%) quantifica il contributo dell’apprendimento per rinforzo in questo problema. Il modello RL ha appreso strategie

non riducibili al gradiente locale: sfruttamento delle informazioni di vento e corrente, navigazione in zone a bassa concentrazione, recupero da situazioni di stallo. Queste strategie emergono dall'ottimizzazione su milioni di episodi con scenari diversificati e non sono accessibili a un metodo che decide step-by-step senza contesto storico.