HYDRAS Project Report v5

1. Algoritmo PPO (Proximal Policy Optimization)

Proximal Policy Optimization (PPO) è un algoritmo di reinforcement learning **on-policy**, appartenente alla famiglia dei **Policy Gradient Methods**. La black-box è strutturata secondo schema **actor-critic**: una rete (policy) produce la distribuzione di probabilità delle azioni, mentre una seconda rete (value function) stima il valore dello stato V(s).

Stable-Baselines3 (SB3) è una libreria open-source per reinforcement learning in Python, costruita su PyTorch. Fornisce implementazioni standardizzate e affidabili dei principali algoritmi (tra cui PPO), con API omogenee per training/inferenza, gestione dei callback, logging e ambienti vettorizzati. In pratica, SB3 è il framework che incapsula la black-box algoritmica e ne rende l'uso riproducibile e comparabile tra esperimenti.

In **Stable-Baselines3**, PPO è implementato con una policy neurale (tipicamente MLP) che elabora l'osservazione e produce due uscite: **policy head** e **value head**. In termini architetturali, il pattern generale è: input osservazionale, hidden layers fully-connected, output su spazio azioni e stima del valore.

Il meccanismo chiave è il **clipped surrogate objective**: PPO massimizza il miglioramento della policy, ma limita la deviazione rispetto alla policy precedente tramite clipping del rapporto $r_t(\theta) = \pi_\theta(a|s) / \pi_{\theta_old}(a|s)$. Questo vincolo riduce update troppo aggressivi e aumenta la stabilità dell'apprendimento.

L'obiettivo complessivo combina tre contributi:
- **Policy loss (clipped)**: aumenta la probabilità delle azioni vantaggiose;
- **Value loss**: allinea la stima V(s) ai ritorni osservati;
- **Entropy bonus**: mantiene esplorazione, evitando policy premature/deterministiche.

Una forma compatta è: $\mathbf{L = L_{clip} + c1 \cdot L_{vf} - c2 \cdot H(\pi)}$.

PPO usa tipicamente **GAE (Generalized Advantage Estimation)** per stimare il vantaggio con buon compromesso bias-varianza. In training la policy è stocastica (campionamento da $\pi(a|s)$); in inferenza può essere resa deterministica scegliendo l'azione a probabilità massima.

2. Dataset — 132 Sorgenti × 4 Scenari Vento

2.1 Acquisizione e Gestione Dati

Sorgente Dati: I dati di concentrazione provengono da simulazioni **MIKE21** in formato NetCDF (1411 timestep, risoluzione 10m, griglia 300×250 celle). Il modulo **data_loader.py** gestisce il caricamento automatico di **132 sorgenti** (SRC001-SRC132) × **4 scenari vento** (V0, V1, V2, V3): legge le coordinate spaziali (x, y), temporali (time) e i valori di concentrazione da file NetCDF, costruendo un campo interpolabile per ogni sorgente. Ogni sorgente ha coordinate geospaziali (UTM32N) caricate da **Coordinate_Sorgenti_FaseII.csv**.

Dataset Split: Dataset suddiviso in **80% training** (~106 sorgenti per scenario vento) e **20% valutazione** (~26 sorgenti held-out per scenario vento), equamente distribuiti tra i 4 scenari V0-V3. Durante il training, il curriculum learning espande progressivamente il set di sorgenti e scenari vento disponibili.

Augmentazione Dati (Chunking): Per massimizzare la variabilità e creare multipli scenari di partenza per ogni sorgente, i 1411 timestep di ogni simulazione vengono suddivisi in **2 chunk temporali**:
• **Chunk 0** (Q1/4, spawn @ 352 timestep): inizio della propagazione del plume, concentrazione ancora concentrata;
• **Chunk 2** (Q3/4, spawn @ 1058 timestep): stadio avanzato, plume pesantemente disperso da vento e correnti.
L'agente può essere inizializzato in fasi diverse della dispersione, aumentando la robustezza del modello. Con **2 ambienti paralleli**, il training esplora combinazioni su **2 chunks × 4 versioni vento** (8 configurazioni), mantenendo 2 scenari attivi simultaneamente.

2.2 I Quattro Scenari Vento (V0, V1, V2, V3)

Il progetto utilizza **4 versioni diverse di vento** (CI_WIND_faseII_V0.txt, V1.txt, V2.txt, V3.txt), generati da simulazioni meteorologiche con parametri e risoluzioni differenti. Questo aumenta vastamente la diversità dei dati di training, permettendo al modello di generalizzare su condizioni vento realistiche. Ogni scenario ha il proprio file di vento (48 timestep) e le correnti oceaniche corrispondenti (estratti da CL02_V0/V1/V2/V3_SRC000_U_V_10mGrid.nc). Durante il training, il curriculum learning espone il modello a tutti e 4 gli scenari progressivamente, creando una policy robust a diverse condizioni meteorologiche.

2.3 Ottimizzazione: Caching In-Memory delle Correnti

Per evitare colli di bottiglia I/O durante il training, il modulo **data_loader.py** implementa un **sistema di caching in-memory** per i dati di vento e corrente:

Meccanismo di Cache: Al startup del DataManager, il metodo **_preload_all_versions_cache()** carica tutti e 4 i file di vento e corrente in RAM (dizionari Python):
• _cached_wind_data = {"V0": array, "V1": array, "V2": array, "V3": array}
• _cached_current_data = {"V0": array, "V1": array, "V2": array, "V3": array}

Durante il training, i metodi **get_wind_data_for_run()** e **get_current_data_for_run()** estraggono i dati dalla cache lookup-by-version, evitando riletture disk. Questo accelera ~5-6× il training rispetto a letture da disco: **~55K step/ora** → **~166K step/ora**.

Sincronizzazione Garantita: La versione (V0/V1/V2/V3) viene estratta dal filename del file NC (es. CL02_V2_SRC042_Conc_10mGrid.nc → V2), quindi è **impossibile un mismatch** tra file di concentrazione, vento e corrente. Tutte le sorgenti di un scenario vento usano lo stesso file di vento/corrente.

3. Ambiente di Simulazione

L'ambiente (**source_seeking_env.py**) è una griglia 300×250 celle (risoluzione 10m) che rappresenta un dominio marino di 3×2.5 km nella baia di Cecina (coste toscane, UTM32N). L'agente (AUV - Autonomous Underwater Vehicle) si muove con **8 azioni discrete**: N, S, E, W, NE, SE, NW, SW. La velocità è **1 m/s** e il timestep **dt=10s**, quindi ogni azione sposta l'agente di 10 metri (o ~7m per componente nelle direzioni diagonali). L'episodio termina quando la sorgente viene raggiunta (distanza < 50m) oppure dopo 1080 step (~3 ore simulate).

Evoluzione Temporale: Il campo di concentrazione evolve nel tempo: ogni 12 step dell'agente (~2 minuti reali) il

campo NetCDF avanza di 1 frame temporale. Vento e corrente sono sincronizzati in minuti reali lungo tutto l'episodio.

3.1 Constraints di Spawn e Fallback Automatico

Procedura di Spawn: L'agente viene inizializzato su una cella del plume (concentrazione > 0.5) rispettando vincoli di distanza dalla sorgente e dalla costa:

Vincolo primario: Seleziona celle con concentrazione > 0.5 dentro l'intervallo **500** $\leq$ **distanza** $\leq$ **1500 metri** dalla sorgente, mantenendo almeno 50 metri dalla terra.

Fallback automatico: Se non trova punti nel range primario (situazione frequente in scenari con plume disperso o costieri), il codice applica rilassamenti progressivi dei vincoli di distanza, mantenendo il vincolo sul plume. Gli step di rilassamento sono: **d** $\geq$ **500m** $\rightarrow$ **d** $\geq$ **375m** $\rightarrow$ **d** $\geq$ **250m** $\rightarrow$ **d** $\geq$ **0m**. La posizione finale viene validata anche dopo il jitter spaziale per rispettare i vincoli attivi.

4. Training e Architettura

4.1 Input della Rete Neurale — 112 Dimensioni

Lo spazio di osservazione è un vettore continuo a **112 dimensioni** (normalizzato via VecNormalize). Includi memoria storica concentrazioni e sensori radiali nelle 8 direzioni:

Componente	Dim	Descrizione
Concentrazione Attuale	1	Conc. posizione corrente (x, y)
Memoria Conc. (Locale)	9	Ultimi 9 timestep
Storico Movimento	18	Δx, Δy ultimi 9 step
Sensori Radiali	8	Conc. ±20m nelle 8 direzioni
Memory Conc. Direzionali	72	Conc. nelle 8 direzioni × 9 timestep
Vento	2	u, v [m/s]
Corrente	2	u, v [m/s]

4.2 Parametri di Training

Parametro	Valore
Architettura Policy	MLP (256-256 unità nascoste, attivazione Tanh)
Normalization	VecNormalize (osservazioni e reward)
Batch Size	128
Learning Rate	2.0e-05
Gamma (discount factor)	0.99
GAE Lambda	0.95
Entropy Coefficient	0.01
Timestep Totali	1.5M (1,500,000)
Curriculum Learning	1 fase di fine-tuning (106 sorgenti × 4 scenari vento)
Ambienti Paralleli	2 worker × 2 chunk = 4 env simultanei

4.3 Funzione di Reward

Componente	Valore/Descrizione
Sorgente Raggiunta	+100.0 + time_bonus (max +50)
Penalità Bordo	-10.0
Plume (dentro)	+1
Plume (fuori)	-1
Reward Distanza	dist_impr × 5.0 × 1.0
Gradiente Conc +	+0.05
Gradiente Conc -	-0.05
Vento (controcorr.)	+0.05
Vento (a favore)	-0.05
Penalità Tempo	-0.1/step
Vicinanza Terra	max -5.0

4.4 Risultati del Training

Modello: ppo_20260414_165629

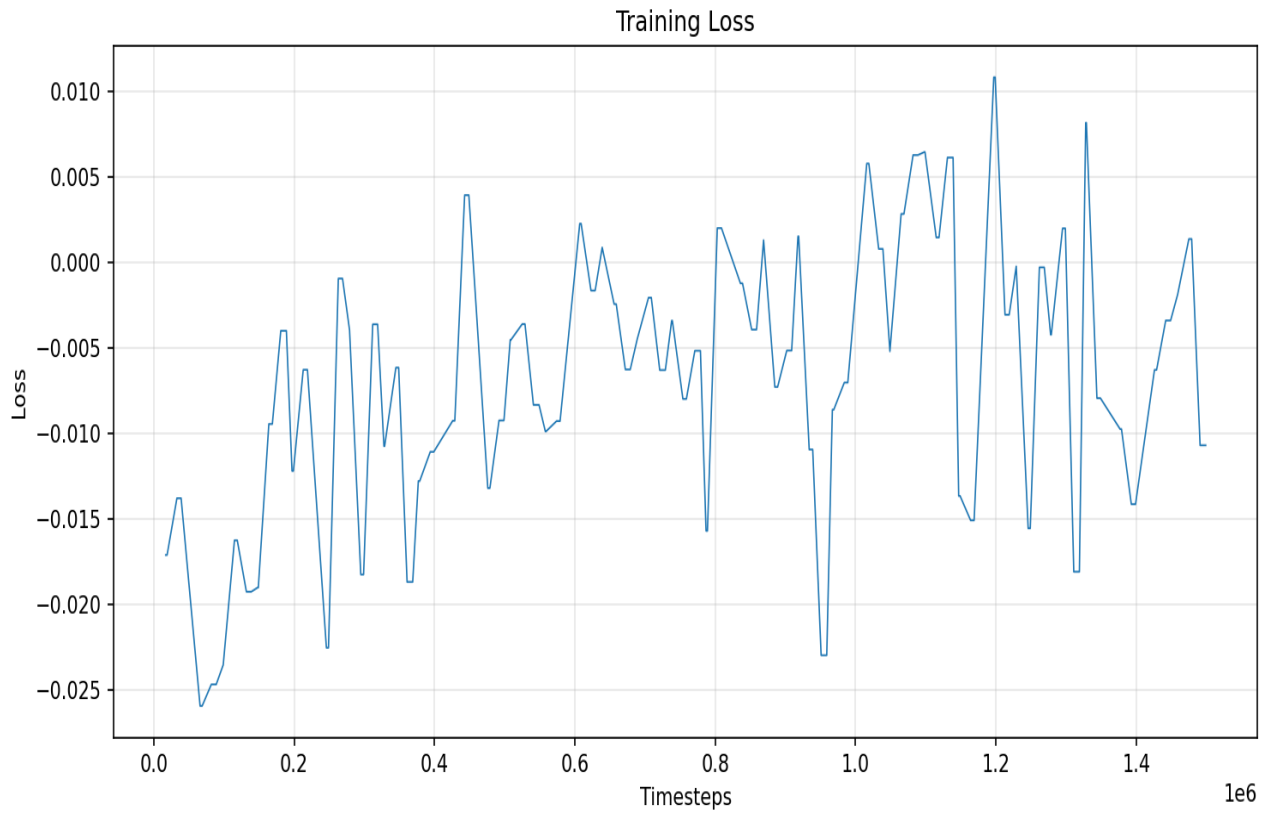

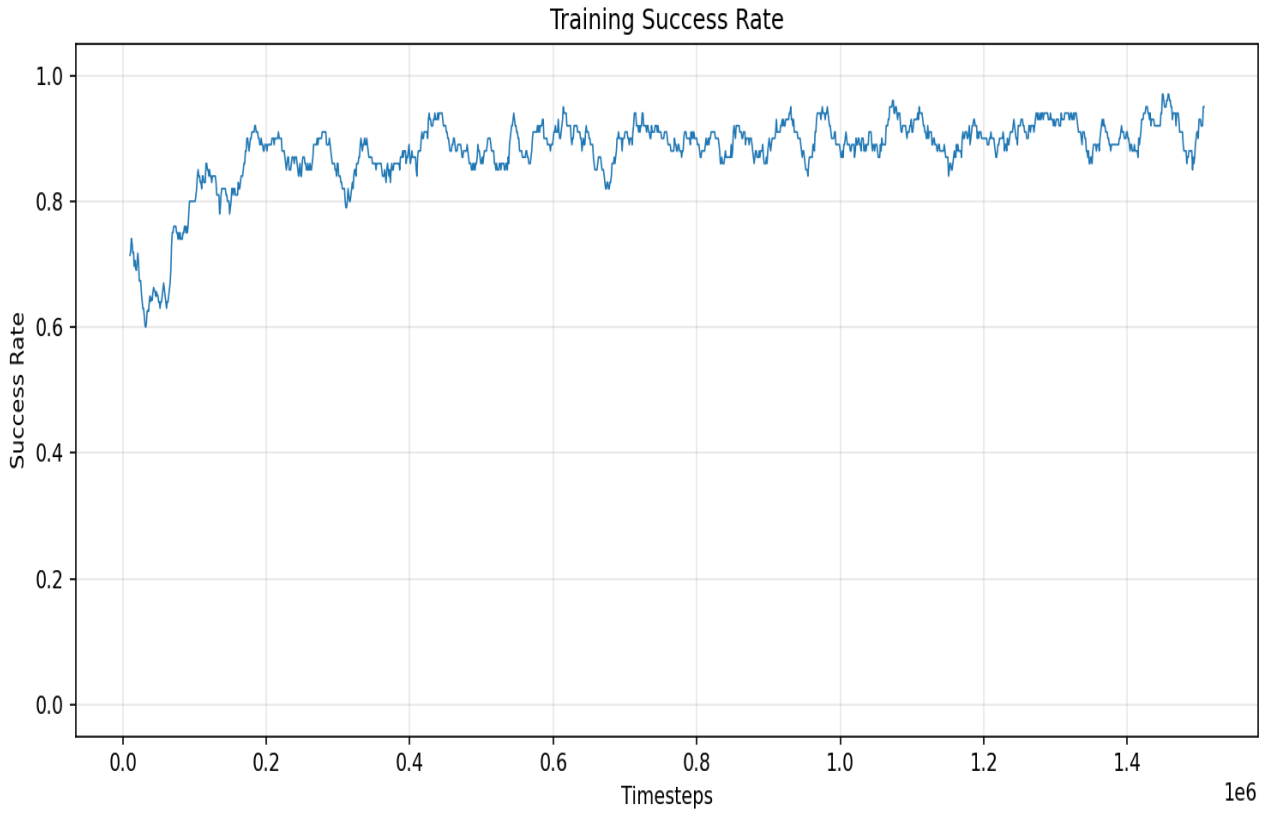

5. Risultati delle Inferenze

Valutazione del modello PPO su **26 sorgenti held-out** (SRC107-SRC132) non viste durante il training curriculum, testato su tutti e **4 scenari vento** (V0, V1, V2, V3). Test eseguito con **vento e correnti reali CMEMS**:

Log inferenza: /Users/mattiamanneschi/PycharmProjects/HYDRAS-Project/evaluations_v5/log.txt
Timestamp inferenza: 2026-04-14 21:27:50
Modello valutato: /Users/mattiamanneschi/PycharmProjects/HYDRAS-Project/trained_models/ppo_20260414_165629/models/final_model.zip

Setup Valutazione:
• **26 sorgenti** × **4 scenari vento** (V0, V1, V2, V3) × **2 chunk temporali** (Q1/4, Q3/4)
• **5 episodi** per configurazione (totale **1040** episodi)
• **Distanza media di partenza**: 592 metri
• **Success @ 50m**: distanza finale ≤ 50m dalla sorgente
• **Timeout @ 1080 steps** (~3.0 ore simulate)

• **Durata media episodio di successo**: 78.4 step (~13.1 min)

Risultati per Tipologia di Vento:
• **V0:** 99.6% success rate
• **V1:** 99.6% success rate
• **V2:** 80.0% success rate
• **V3:** 100.0% success rate

Risultati per Frame Temporale:
• **Q1/4:** 99.8% success rate
• **Q3/4:** 89.8% success rate
Successo Globale: 94.8% (media su tutti i 208 scenari)

Analisi dei Fallimenti: I fallimenti residui si concentrano ormai in alcuni casi dello **scenario V2**, soprattutto nel **chunk Q3/4**. In queste configurazioni il plume si disperde a "macchia d'olio": il gradiente locale diventa debole e discontinuo, quindi l'agente fatica a mantenere una direzione affidabile verso la sorgente e può terminare in **timeout**.

Esempi di Fallimento V2 (Q3/4)

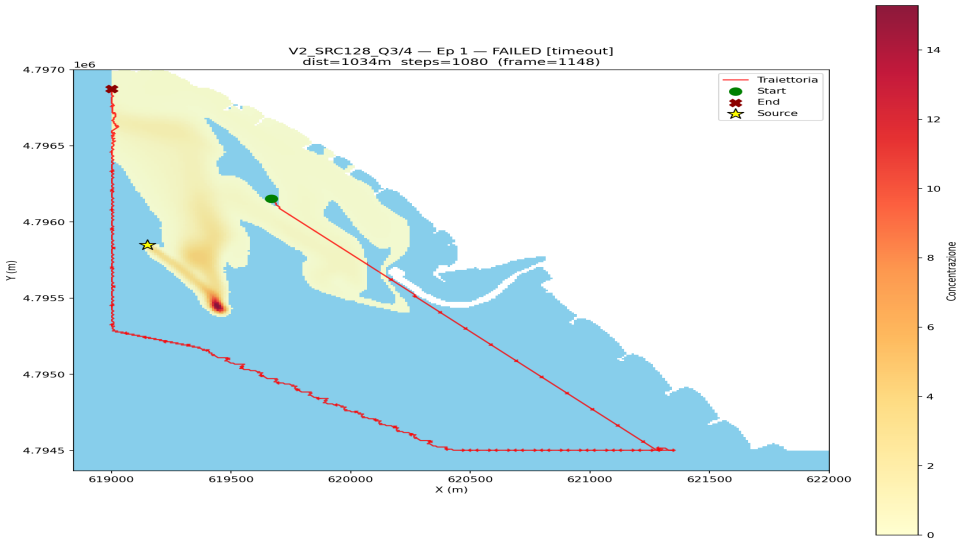

***SRC128 - Ep1**: FAILED [timeout], dist finale 1034m. Dispersione elevata e percorso erratico lontano dalla sorgente.*

Altri Esempi di Fallimento V2 (Q3/4)

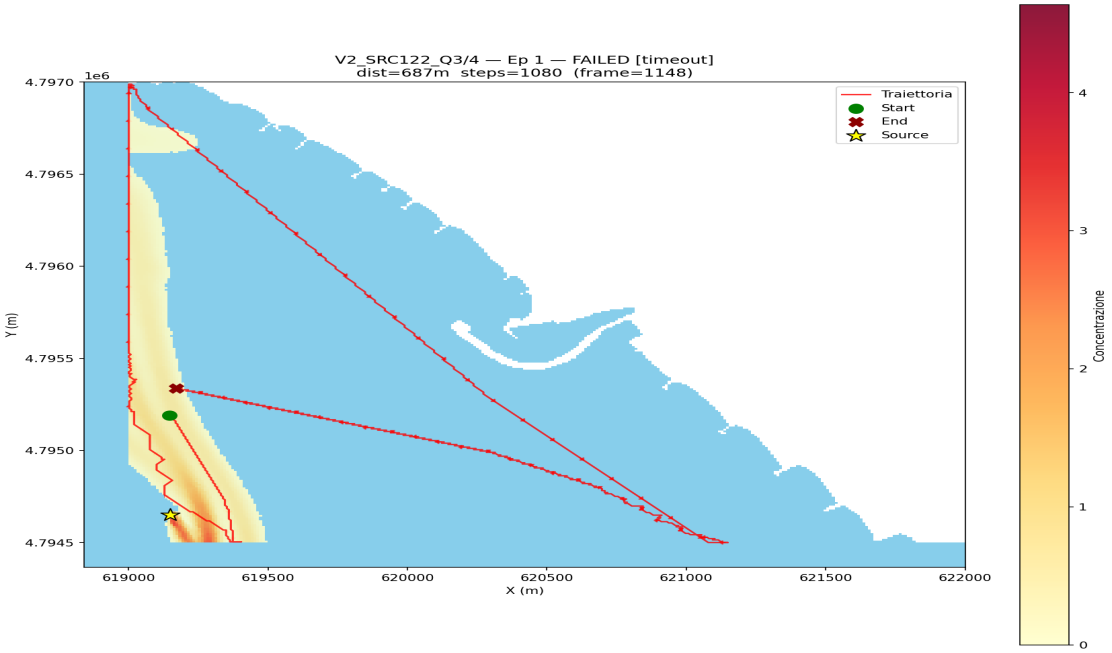

***SRC122 - Ep1**: FAILED [timeout], dist finale 687m. Plume molto diffuso e traiettoria non convergente.*

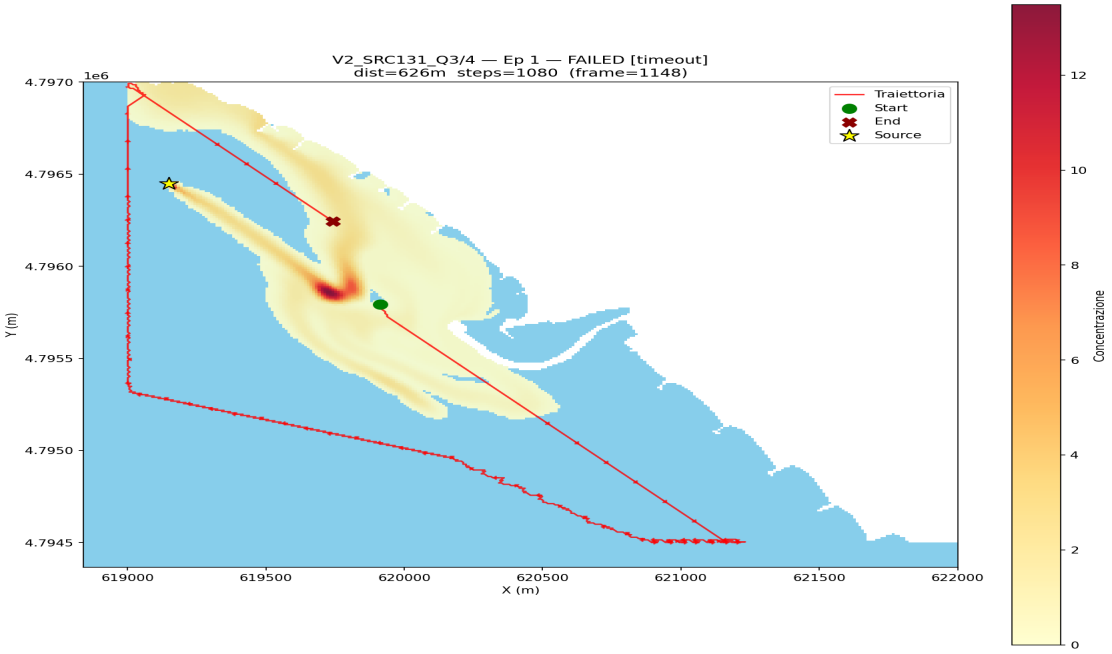

***SRC131 - Ep1**: FAILED [timeout], dist finale 626m. Deriva fuori plume e perdita del gradiente utile.*