HYDRAS Project Report v6

1. Algoritmo PPO (Proximal Policy Optimization)

Proximal Policy Optimization (PPO) è un algoritmo di reinforcement learning **on-policy**, appartenente alla famiglia dei **Policy Gradient Methods**. La black-box è strutturata secondo uno schema **actor-critic**: una rete (policy) produce la distribuzione di probabilità delle azioni, mentre una seconda rete (value function) stima il valore dello stato V(s).

Stable-Baselines3 (SB3) è una libreria open-source per reinforcement learning in Python, costruita su PyTorch. Fornisce implementazioni standardizzate e affidabili dei principali algoritmi (tra cui PPO), con API omogenee per training/inferenza, gestione dei callback, logging e ambienti vettorizzati. In pratica, SB3 è il framework che incapsula la black-box algoritmica e ne rende l'uso riproducibile e comparabile tra esperimenti.

In **Stable-Baselines3**, PPO è implementato con una policy neurale (tipicamente MLP) che elabora l'osservazione e produce due uscite: **policy head** e **value head**. In termini architetturali, il pattern generale è: input osservazionale, hidden layers fully-connected, output su spazio azioni e stima del valore.

Il meccanismo chiave è il **clipped surrogate objective**: PPO massimizza il miglioramento della policy, ma limita la deviazione rispetto alla policy precedente tramite clipping del rapporto $r_t(\theta) = \pi_\theta(a|s) / \pi_{\theta_old}(a|s)$. Questo vincolo riduce update troppo aggressivi e aumenta la stabilità dell'apprendimento.

L'obiettivo complessivo combina tre contributi:
- **Policy loss (clipped)**: aumenta la probabilità delle azioni vantaggiose;
- **Value loss**: allinea la stima V(s) ai ritorni osservati;
- **Entropy bonus**: mantiene esplorazione, evitando policy premature/deterministiche.

Una forma compatta è: $\mathbf{L = L_{clip} + c1 \cdot L_{vf} - c2 \cdot H(\pi)}$.

PPO usa tipicamente **GAE (Generalized Advantage Estimation)** per stimare il vantaggio con buon compromesso bias-varianza. In training la policy è stocastica (campionamento da $\pi(a|s)$); in inferenza può essere resa deterministica scegliendo l'azione a probabilità massima.

2. Dataset — 132 Sorgenti × 4 Scenari Vento

2.1 Acquisizione e Gestione Dati

Sorgente Dati: I dati di concentrazione provengono da simulazioni **MIKE21** in formato NetCDF (1411 timestep, risoluzione 10m, griglia 300×250 celle). Il modulo **data_loader.py** gestisce il caricamento automatico di **132 sorgenti** (SRC001-SRC132) × **4 scenari vento** (V0, V1, V2, V3): legge le coordinate spaziali (x, y), temporali (time) e i valori di concentrazione da file NetCDF, costruendo un campo interpolabile per ogni sorgente. Ogni sorgente ha coordinate geospaziali (UTM32N) caricate da **Coordinate_Sorgenti_FaseII.csv**.

Dataset Split: Dataset suddiviso in **80% training** (~106 sorgenti per scenario vento) e **20% valutazione** (~26 sorgenti held-out per scenario vento), equamente distribuiti tra i 4 scenari V0-V3. Durante il training, il curriculum learning espande progressivamente il set di sorgenti e scenari vento disponibili.

Augmentazione Dati (Chunking): Per massimizzare la variabilità e creare multipli scenari di partenza per ogni sorgente, i 1411 timestep di ogni simulazione vengono suddivisi in **3 chunk temporali**:
• **Chunk 0** (Q1/4, spawn @ 352 timestep): inizio della propagazione del plume, concentrazione ancora concentrata;
• **Chunk 1** (Q1/2, spawn @ metà simulazione): stadio intermedio, plume parzialmente disperso;
• **Chunk 2** (Q3/4, spawn @ 1058 timestep): stadio avanzato, plume pesantemente disperso da vento e correnti.
L'agente può essere inizializzato in tre fasi diverse della dispersione, aumentando la robustezza del modello. Il training usa **1 worker per chunk = 3 ambienti simultanei**, coprendo tutte le combinazioni **3 chunk × 4 versioni vento**.

2.2 I Quattro Scenari Vento (V0, V1, V2, V3)

Il progetto utilizza **4 versioni diverse di vento** (CI_WIND_faseII_V0.txt, V1.txt, V2.txt, V3.txt), generati da simulazioni meteorologiche con parametri e risoluzioni differenti. Questo aumenta vastamente la diversità dei dati di training, permettendo al modello di generalizzare su condizioni vento realistiche. Ogni scenario ha il proprio file di vento (48 timestep) e le correnti oceaniche corrispondenti (estratti da CL02_V0/V1/V2/V3_SRC000_U_V_10mGrid.nc). Durante il training, il curriculum learning espone il modello a tutti e 4 gli scenari progressivamente, creando una policy robusta a diverse condizioni meteorologiche.

2.3 Ottimizzazione: Caching In-Memory delle Correnti

Per evitare colli di bottiglia I/O durante il training, il modulo **data_loader.py** implementa un **sistema di caching in-memory** per i dati di vento e corrente:

Meccanismo di Cache: Al startup del DataManager, il metodo **_preload_all_versions_cache()** carica tutti e 4 i file di vento e corrente in RAM (dizionari Python):
• _cached_wind_data = {"V0": array, "V1": array, "V2": array, "V3": array}
• _cached_current_data = {"V0": array, "V1": array, "V2": array, "V3": array}

Durante il training, i metodi **get_wind_data_for_run()** e **get_current_data_for_run()** estraggono i dati dalla cache lookup-by-version, evitando riletture disk. Questo accelera ~5-6× il training rispetto a letture da disco: **~55K step/ora** → **~166K step/ora**.

Sincronizzazione Garantita: La versione (V0/V1/V2/V3) viene estratta dal filename del file NC (es. CL02_V2_SRC042_Conc_10mGrid.nc → V2), quindi è **impossibile un mismatch** tra file di concentrazione, vento e corrente. Tutte le sorgenti di un scenario vento usano lo stesso file di vento/corrente.

3. Ambiente di Simulazione

L'ambiente (**source_seeking_env.py**) è una griglia 300×250 celle (risoluzione 10m) che rappresenta un dominio marino di 3×2.5 km nella baia di Cecina (coste toscane, UTM32N). L'agente (AUV - Autonomous Underwater Vehicle) si muove con **8 azioni discrete**: N, S, E, W, NE, SE, NW, SW. La velocità è **1 m/s** e il timestep **dt=10s**, quindi ogni azione sposta l'agente di 10 metri (o ~7m per componente nelle direzioni diagonali). L'episodio termina quando la sorgente viene raggiunta (distanza < 50m) oppure dopo 1080 step (~3 ore simulate).

Evoluzione Temporale: Il campo di concentrazione evolve nel tempo: ogni 12 step dell'agente (~2 minuti reali) il campo NetCDF avanza di 1 frame temporale. Vento e corrente sono sincronizzati in minuti reali lungo tutto l'episodio.

3.1 Constraints di Spawn e Fallback Automatico

Procedura di Spawn a Cascata: L'agente viene inizializzato su una cella del plume (concentrazione > 0.5) rispettando vincoli di distanza dalla sorgente e dalla costa. La procedura prova anelli concentrici in ordine decrescente di distanza, garantendo spawn sempre lontani dalla sorgente quando possibile:

Cascata di anelli (dal più lontano al più vicino):
• (2000–2500 m) → (1500–2000 m) → (1000–1500 m) → (500–1000 m) → (250–500 m) → (50–250 m) → (0–50 m)

Per ogni anello, vengono selezionate celle con **concentrazione > 0.5** e distanza dalla terra ≥ 50 m. La cascata scende all'anello successivo solo se nessun punto del plume rientra in quello corrente. **Fallback finale:** se nessun anello ha celle valide, lo spawn avviene ovunque nel plume senza vincoli di distanza.

4. Training e Architettura

4.1 Input della Rete Neurale — 112 Dimensioni

Lo spazio di osservazione è un vettore continuo a **112 dimensioni** (normalizzato via VecNormalize). Include la memoria storica delle concentrazioni e sensori radiali nelle 8 direzioni:

Componente	Dim	Descrizione
Concentrazione Attuale	1	Conc. posizione corrente (x, y)
Memoria Conc. (Locale)	9	Ultimi 9 timestep
Storico Movimento	18	Δx, Δy ultimi 9 step
Sensori Radiali	8	Conc. ±20m nelle 8 direzioni
Memory Conc. Direzionali	72	Conc. nelle 8 direzioni × 9 timestep
Vento	2	u, v [m/s]
Corrente	2	u, v [m/s]

4.2 Parametri di Training

Parametro	Valore
Architettura Policy	MLP (256-256 unità nascoste, attivazione Tanh)
Normalization	VecNormalize (solo osservazioni)
Batch Size	128
Learning Rate	2.0e-05
Gamma (discount factor)	0.99
GAE Lambda	0.95
Entropy Coefficient	0.01
Timestep Totali	1.5M (1,500,000)
Curriculum Learning	1 fase di fine-tuning (106 sorgenti × 4 scenari vento)
Ambienti Paralleli	1 worker × 3 chunk = 3 env simultanei

4.3 Funzione di Reward

Componente	Valore/Descrizione
Sorgente Raggiunta	+100.0 + time_bonus (max +50)
Penalità Bordo	-10.0
Plume (dentro)	+0.5
Plume (fuori)	-0.2
Plume (resta nel plume)	0.0
Plume (esce dal plume)	-0.5
Reward Distanza	dist_impr × 0.05 × 1.0
Stagnazione	-1.5 dopo 20 step senza >20m
Gradiente Conc +	+0.05
Gradiente Conc -	-0.05
Vento (controvento)	+0.05
Vento (a favore del vento)	-0.05

Corrente (controcorrente)	+0.05
Corrente (a favore della corrente)	-0.05
Penalità Tempo	-0.1/step
Vicinanza Terra	max -5.0

4.4 Risultati del Training

Modello: ppo_20260423_182359

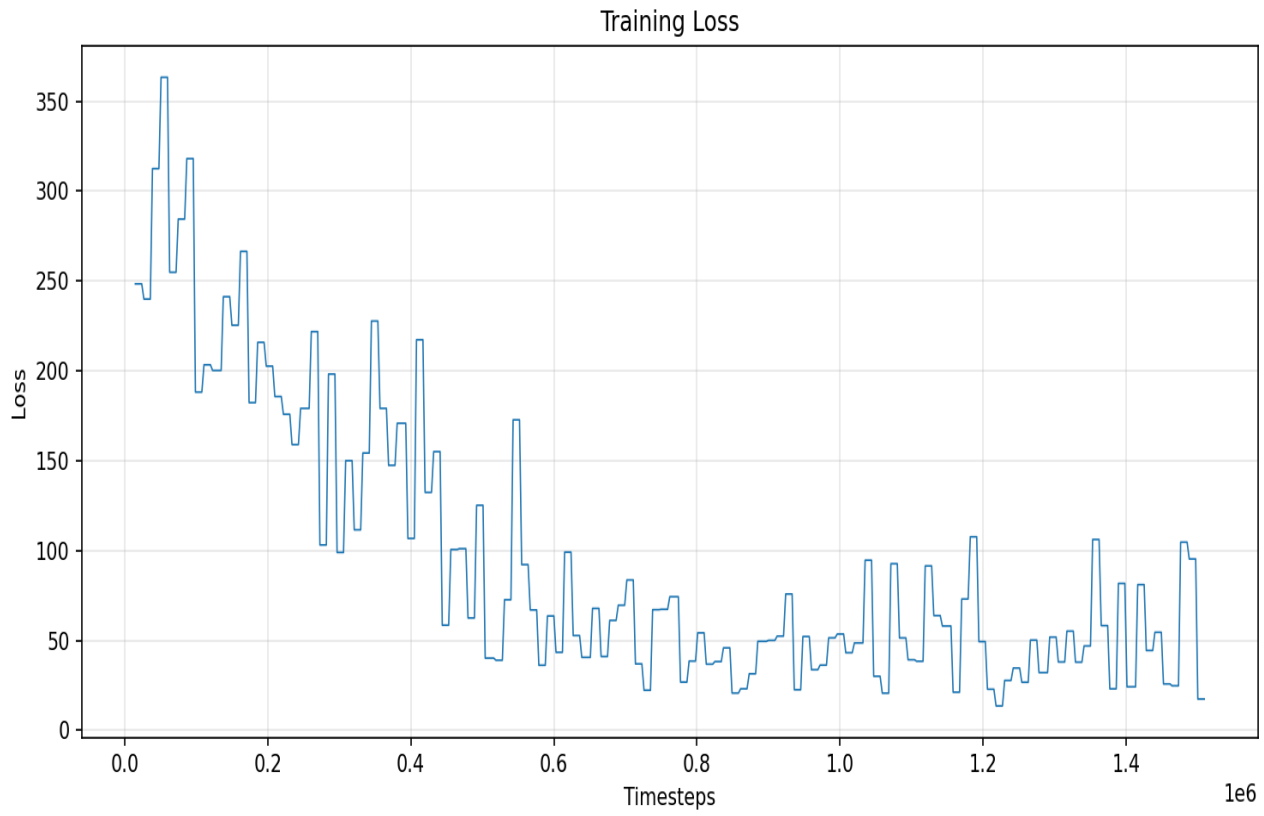

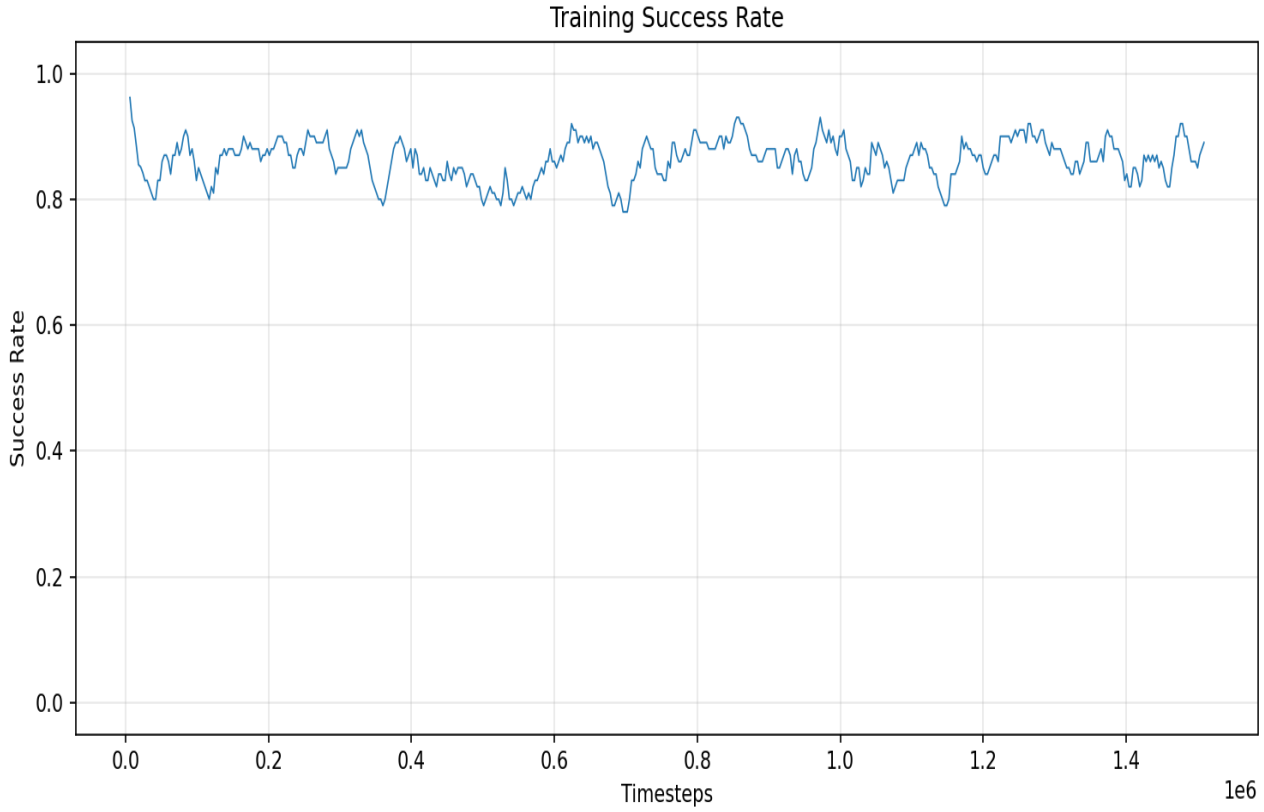

5. Risultati delle Inferenze

Il modello PPO addestrato è stato valutato su **26 sorgenti held-out** (SRC107–SRC132), mai viste durante il training. Il test copre tutti e **4 gli scenari vento** (V0–V3) su **3 chunk temporali** (Q1/4, Q1/2, Q3/4), con vento e correnti reali CMEMS.

Modello: ppo_20260423_182359 | **Generato:** 2026-04-24 08:25:40

5.1 Setup di Valutazione

Parametro	Valore
Sorgenti held-out	26 (SRC107–SRC132)
Scenari vento	4 (V0, V1, V2, V3)
Chunk temporali	3 (Q1/4, Q1/2, Q3/4)
Episodi per configurazione	3
Totale episodi	936
Distanza media di partenza	808 m
Criterio di successo	distanza finale ≤ 50 m dalla sorgente
Timeout	1080 step (~3.0 h simulate)
Durata media episodio riuscito	149 step (~24.9 min)

5.2 Risultati

Scenario Vento	Success Rate
V0	98.7%
V1	90.6%
V2	79.1%
V3	99.1%

Chunk Temporale	Success Rate
Q1/4	100.0%
Q1/2	85.3%
Q3/4	90.4%

Successo Globale: **92.0%** su 312 scenari × 3 episodi = 936 episodi totali

5.3 Analisi dei Fallimenti

I fallimenti residui si concentrano nello **scenario V2**, in particolare nei **chunk Q1/2 e Q3/4**. In queste configurazioni il plume si disperde a "macchia d'olio": il gradiente locale diventa debole e discontinuo, rendendo impossibile per l'agente mantenere una direzione affidabile verso la sorgente. L'episodio termina quindi in **timeout** senza convergenza.

5.4 Esempi di Traiettorie

Successi

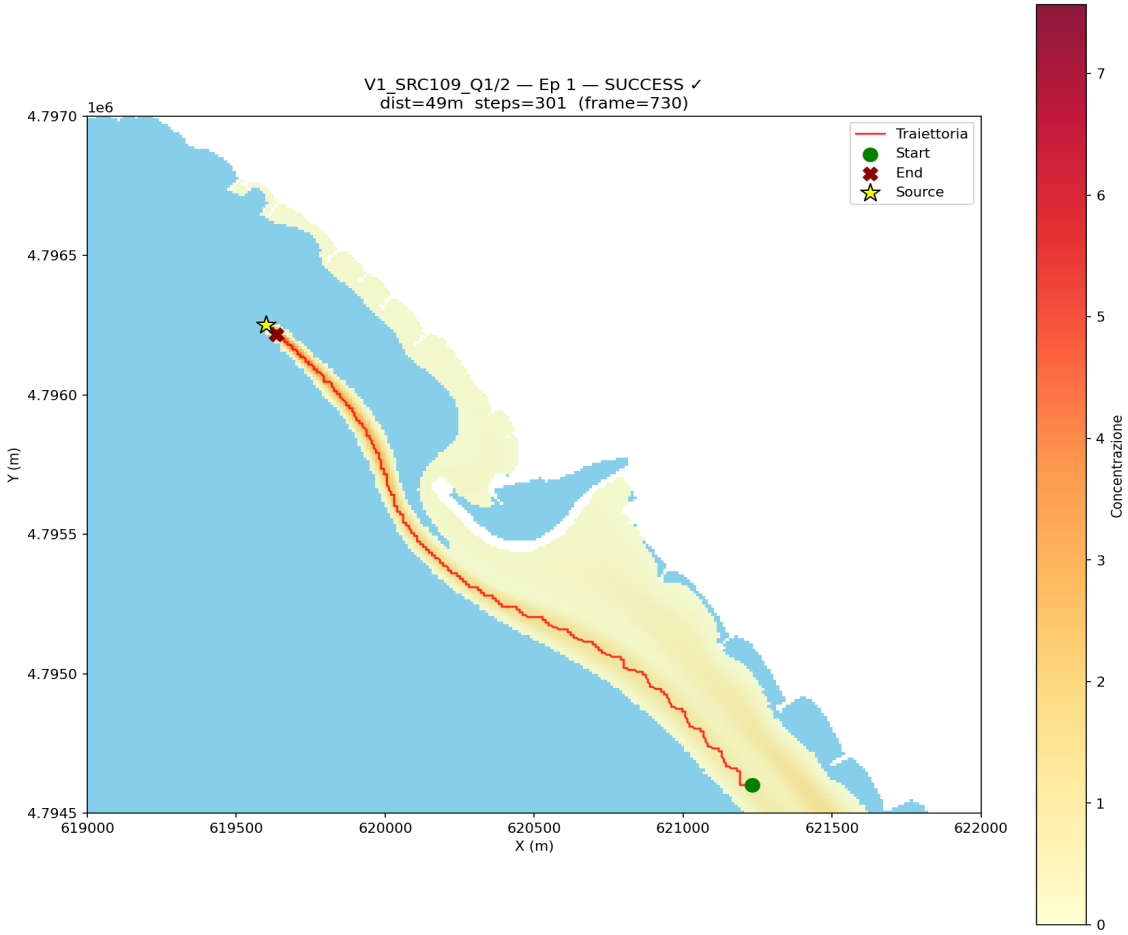
V1_SRC109_Q1/2 — Ep 1 — SUCCESS ✓
dist=49m steps=301 (frame=730)
1e6
Traiettoria
Start
End
Source
Y (m)
X (m)
Concentrazione

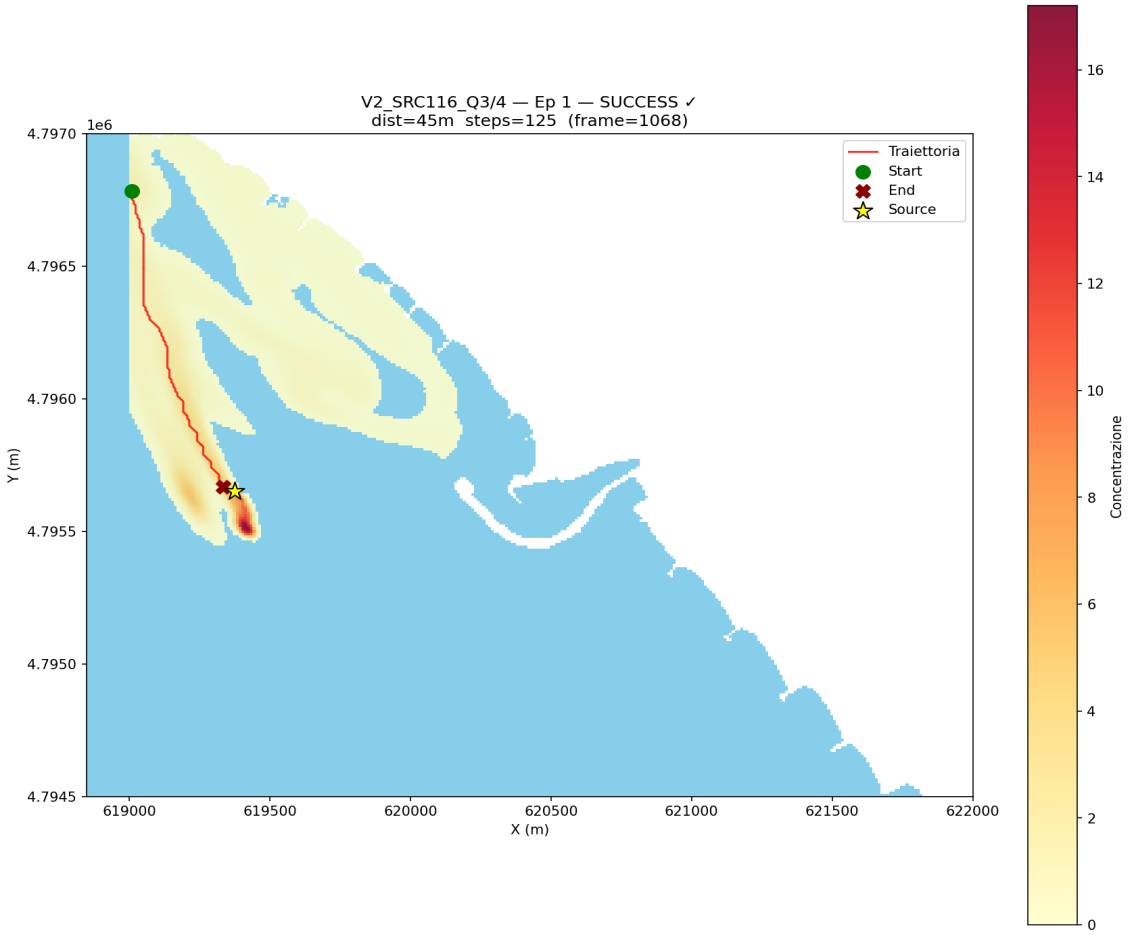
V2_SRC116_Q3/4 — Ep 1 — SUCCESS ✓
dist=45m steps=125 (frame=1068)
1e6
Traiettoria
Start
End
Source
Y (m)
X (m)
Concentrazione

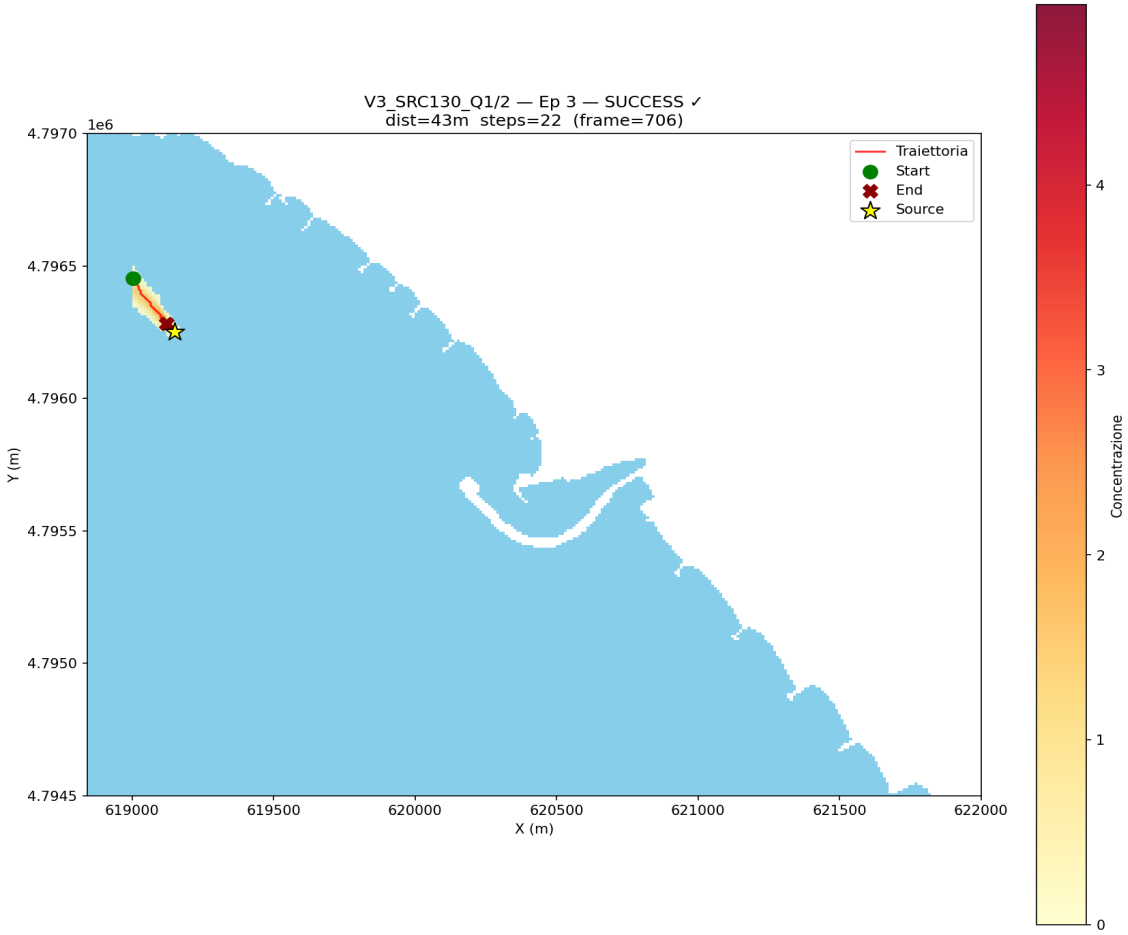
V3_SRC130_Q1/2 — Ep 3 — SUCCESS ✓
dist=43m steps=22 (frame=706)
1e6
4.7970
4.7965
4.7960
4.7955
4.7950
4.7945
Y (m)
619000
619500
620000
620500
621000
621500
622000
X (m)
Traiettoria
Start
End
Source
Concentrazione
0
1
2
3
4

Fallimenti

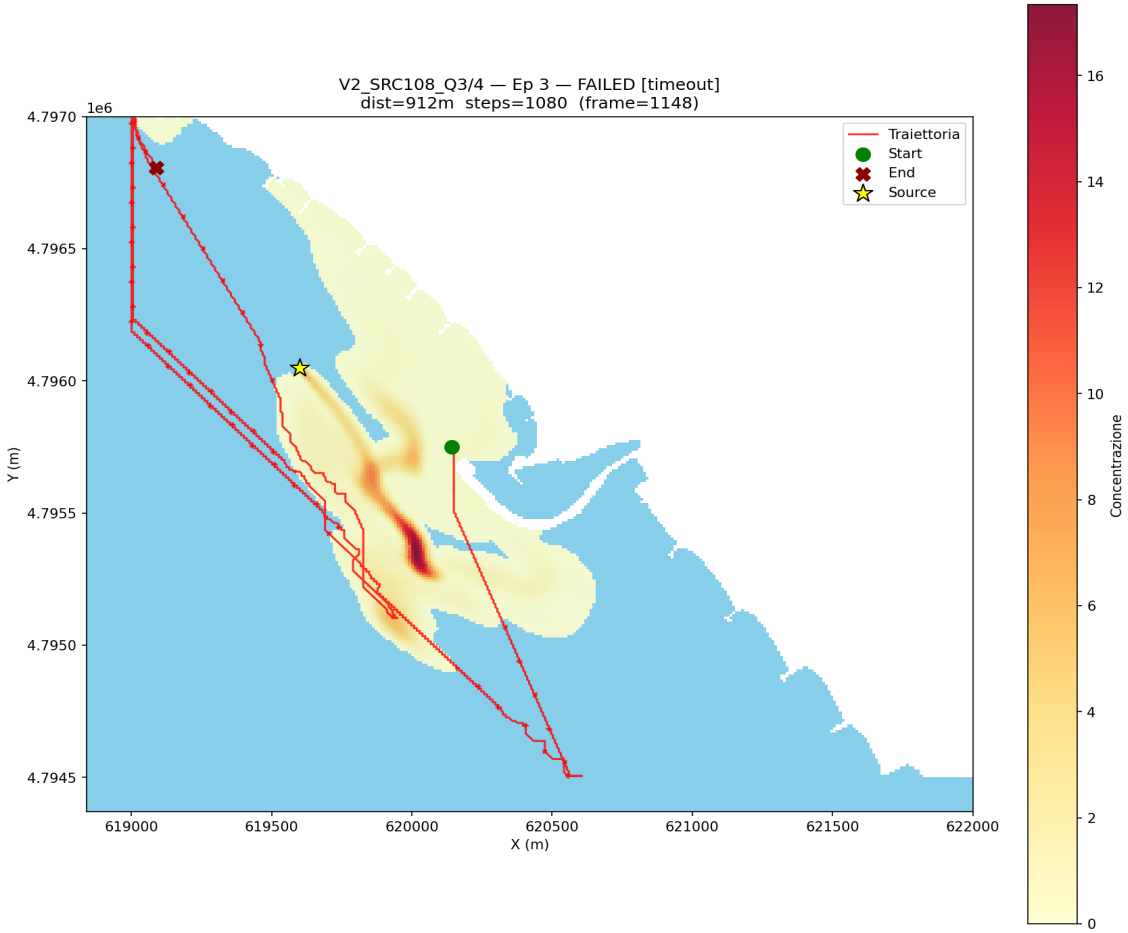
V2_SRC108_Q3/4 — Ep 3 — FAILED [timeout]
dist=912m steps=1080 (frame=1148)
1e6
Traiettoria
Start
End
Source
Y (m)
X (m)
Concentrazione

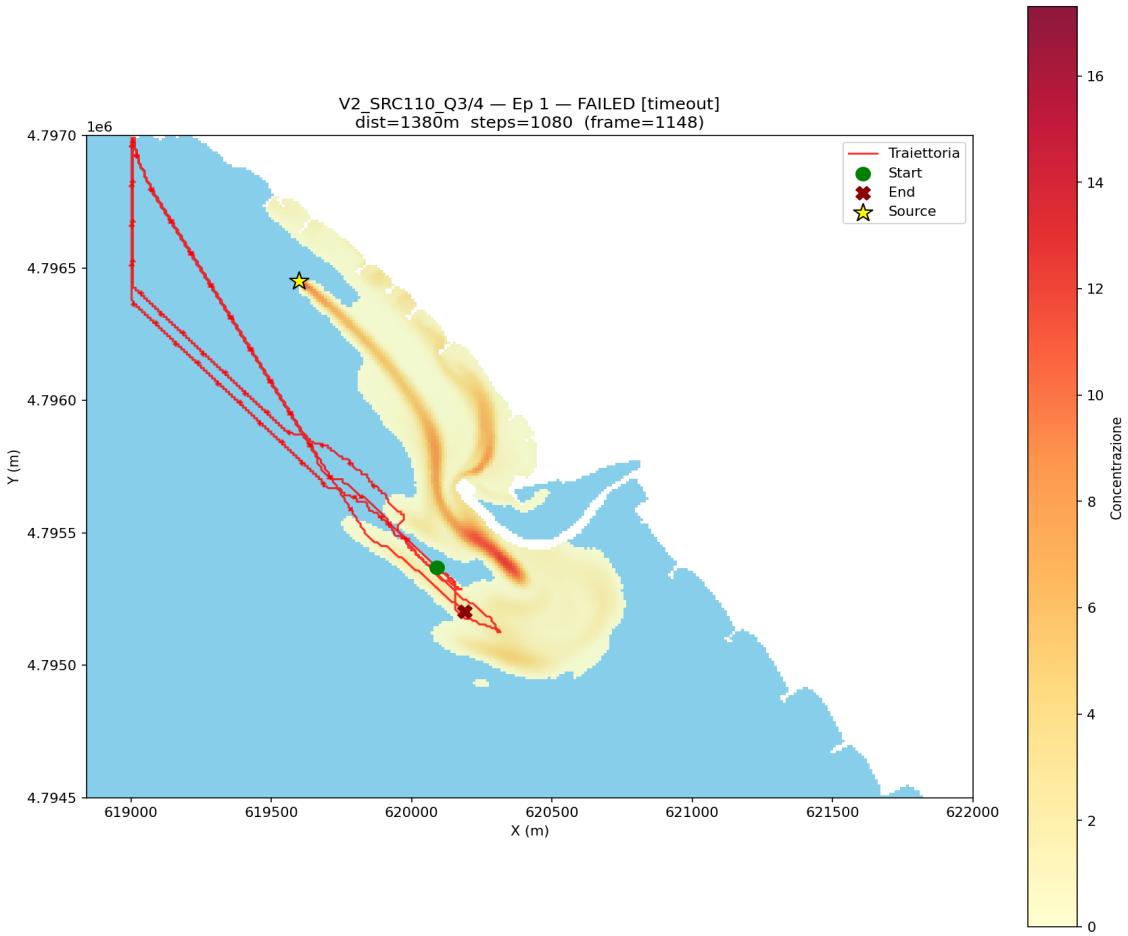
V2_SRC110_Q3/4 — Ep 1 — FAILED [timeout]
dist=1380m steps=1080 (frame=1148)
1e6
Traiettoria
Start
End
Source
Y (m)
X (m)
Concentrazione

6. Analisi Quantitativa dei Risultati

Analisi dettagliata condotta su **936 episodi** raccolti durante l'inferenza (860 successi, 76 fallimenti). I dati provengono da: *evaluations_v6/episodes_data.json*.

6.1 Distribuzione dei Tempi di Successo

Istogramma dei tempi simulati impiegati dall'agente per raggiungere la sorgente, limitato al 95° percentile dei successi per evidenziare la struttura principale della distribuzione. Il box in basso a destra riporta le statistiche complete inclusi gli outlier. La distribuzione è asimmetrica a destra: la maggior parte dei successi avviene entro 20 minuti simulati, con una coda dovuta a scenari più complessi (plume disperso, spawn lontano).

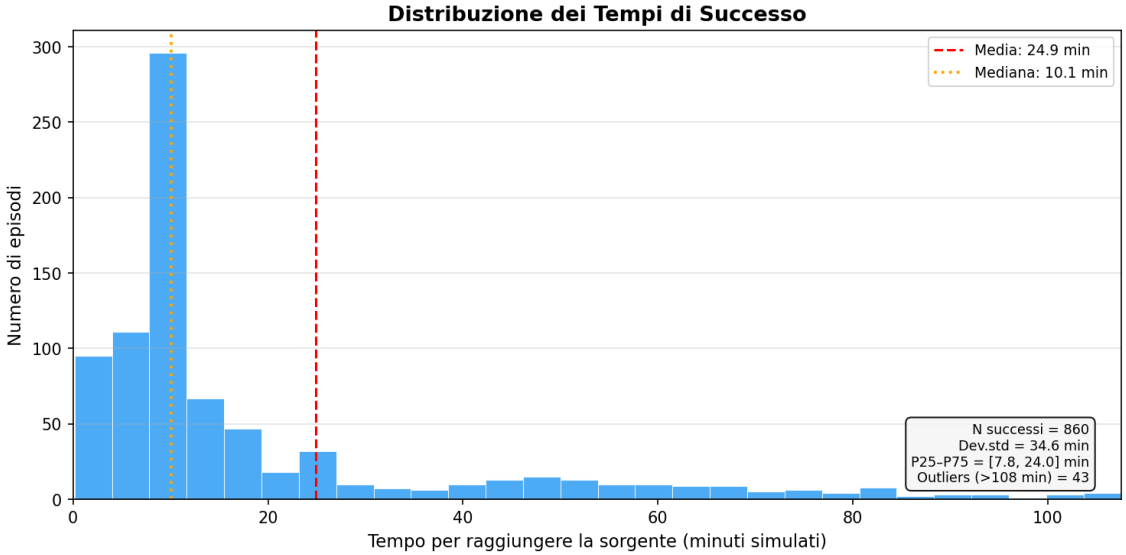

6.2 Successo Atteso in Funzione dello Scenario

Sinistra: heatmap della success rate per ogni combinazione versione vento × chunk temporale. Evidenzia quali scenari sono strutturalmente più difficili (V2, chunk avanzati). **Destra:** success rate in funzione della distanza iniziale di spawn dalla sorgente (bins da 500 m).

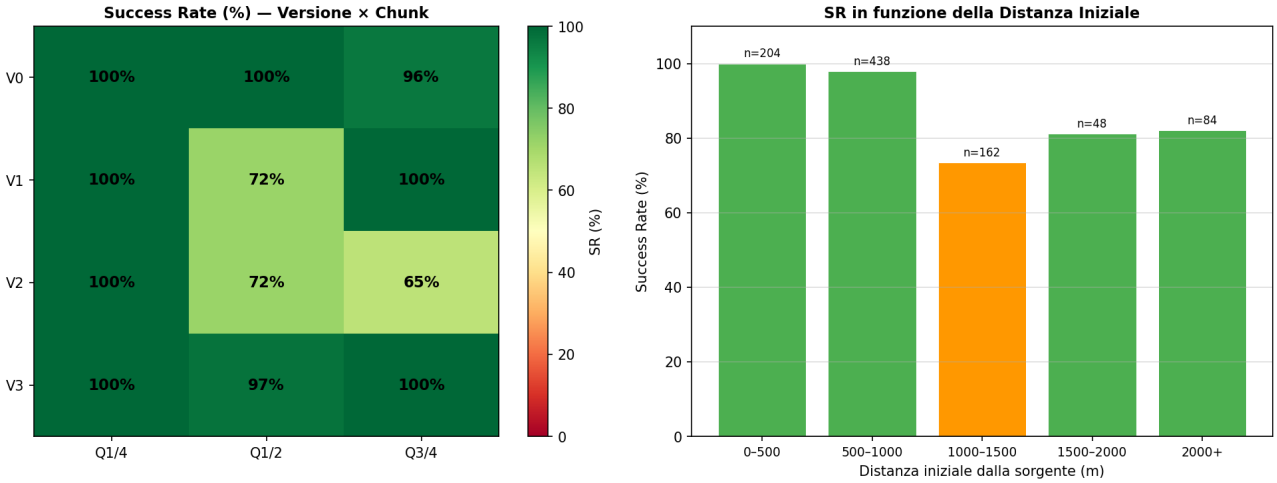

6.3 Distanza dalla Sorgente nel Tempo
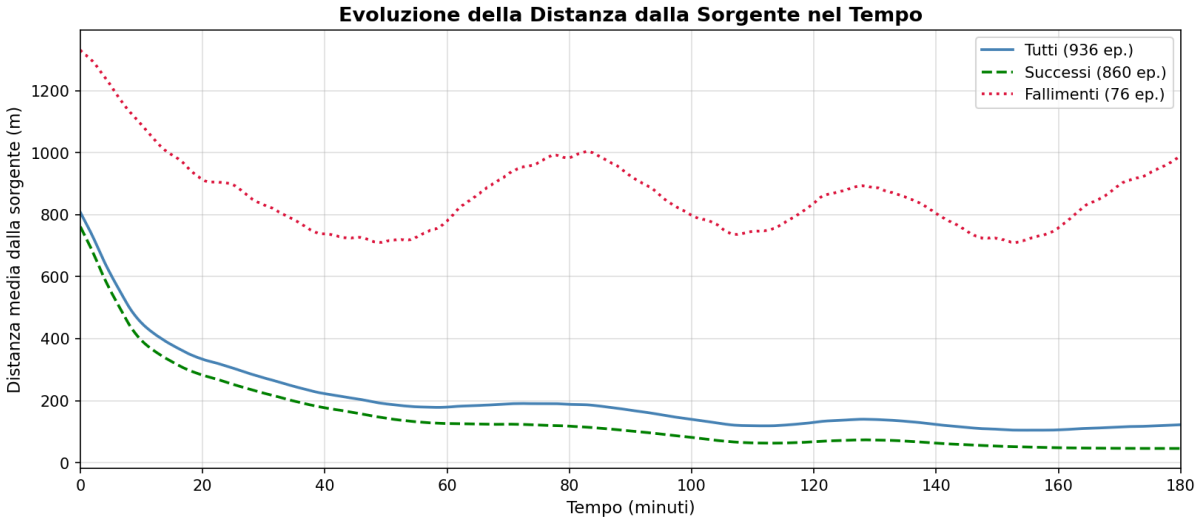
Distanza media dalla sorgente in funzione del tempo simulato (in minuti), mediata su tutti gli episodi. Le curve separate per successi e fallimenti mostrano il diverso comportamento di convergenza: gli episodi di successo mostrano una riduzione progressiva e sostenuta della distanza, mentre i fallimenti tendono a oscillare o stabilizzarsi a distanze elevate.