

HYDRAS — Report v10

Studio di Ablation della Funzione di Reward

1 Algoritmo PPO

L'agente è addestrato con **MaskablePPO** (sb3-contrib), estensione di Proximal Policy Optimization che integra l'action masking per impedire collisioni con la costa. L'architettura della policy è una MLP con due reti separate (attore e critico), ciascuna composta da due strati nascosti da 256 neuroni con attivazione tanh. Il training utilizza **SubprocVecEnv** con 6 worker paralleli ($2 \text{ worker} \times 3 \text{ chunk}$) avviati con `start_method='fork'` per ridurre l'overhead di inizializzazione e raggiungere un throughput di circa 300 K step/ora.

2 Dataset — 132 Sorgenti $\times$ 4 Scenari Vento

2.1 Acquisizione e Gestione Dati

Il dataset è composto da simulazioni oceanografiche MIKE21 su un dominio marino di 3×2.5 km nella baia di Cecina (costa toscana, UTM32N), con risoluzione spaziale di 10 m e passo temporale di 10 s. Ogni sorgente è identificata da un codice univoco (SRC001–SRC132); per ciascuna sorgente sono disponibili 4 file di concentrazione corrispondenti ai 4 scenari di vento V0–V3, caratterizzati da direzioni e intensità differenti che generano plume con morfologie diverse.

Il dataset è suddiviso in modo da garantire una valutazione su sorgenti mai viste durante il training:

- **Training:** SRC001–SRC106 (80%, 106 sorgenti)
- **Inferenza:** SRC107–SRC132 (20%, 26 sorgenti)

3 Ambiente di Simulazione

L'ambiente implementa l'interfaccia `gymnasium.Env` con spazio delle azioni discreto a 8 direzioni. Ogni episodio ha una durata massima di 1080 step (= 3 h di tempo simulato). Il dataset è suddiviso in 3 chunk temporali (Q1/4, Q1/2, Q3/4) per variare le condizioni iniziali del campo di concentrazione lungo l'asse temporale della simulazione.

3.1 Constraints di Spawn e Fallback Automatico

L'agente viene inizializzato su una cella del plume (concentrazione $c \geq 0.5$) rispettando vincoli di distanza dalla sorgente e dalla costa. La procedura adotta una **cascata di anelli concentrici** in ordine decrescente di distanza dalla sorgente, garantendo spawn sempre lontani quando possibile:

$$(2000\text{--}2500 \text{ m}) \rightarrow (1500\text{--}2000 \text{ m}) \rightarrow (1000\text{--}1500 \text{ m}) \rightarrow (500\text{--}1000 \text{ m}) \rightarrow (250\text{--}500 \text{ m}) \rightarrow (50\text{--}250 \text{ m}) \rightarrow (0\text{--}50 \text{ m})$$

Per ogni anello vengono selezionate le celle con $c \geq 0.5$ e distanza dalla terra ≥ 50 m; la cascata scende all'anello successivo solo se nessuna cella del corrente soddisfa entrambe

le condizioni. **Fallback finale:** se nessun anello produce celle valide, lo spawn avviene in qualsiasi cella del plume senza vincoli di distanza dalla sorgente.

4 Training e Architettura

4.1 Input della Rete Neurale — 116 Dimensioni

L’observation space è composto da 116 dimensioni che forniscono all’agente una rappresentazione completa del campo chimico locale, della propria cinematica e delle condizioni ambientali (vento e corrente). Tutte le feature sono normalizzate nell’intervallo $[0, 1]$ o $[-1, 1]$.

Feature	Dim.	Descrizione
Concentrazione attuale	1	Concentrazione nella posizione corrente
Memoria concentrazione	9	Ultime 9 letture di concentrazione
Memoria spostamenti	18	Ultimi 9 spostamenti $(\Delta x, \Delta y)$ in metri
Sensori direzionali (correnti)	8	Concentrazione nelle 8 direzioni a 20 m (step corrente)
Memoria sensori direzionali	72	Concentrazione nelle 8 direzioni per i 9 timestep passati
Vento	2	u, v [m/s] correnti
Corrente	2	u, v [m/s] correnti
Direzione max conc. vista	2	$(\Delta x, \Delta y)$ verso la posizione di concentrazione massima osservata nell’episodio
Valore max conc. vista	1	Valore di concentrazione massima osservata nell’episodio
Step senza plume	1	Step dall’ultimo contatto col plume (normalizzato su <code>max_steps</code>)

Tabella 1: Input della rete neurale: 116 dimensioni totali.

4.2 Parametri di Training

I tre modelli dell’ablation study condividono gli stessi iperparametri; l’unica differenza tra le rispettive configurazioni è il parametro `reward_mode`. Il learning rate segue uno schedule a gradini decrescenti e la distribuzione degli scenari evolve tramite un parametro $\alpha \in [0, 1]$: per $\alpha = 0$ la distribuzione è uniforme, per $\alpha \rightarrow 1$ il peso è concentrato sugli scenari più difficili (V2) e sui chunk temporali centrali.

Step	LR
0 – 2 000 000	3×10^{-4}
2 000 000 – 4 000 000	1×10^{-4}
4 000 000 – 5 000 000	5×10^{-5}
5 000 000 – 6 000 000	1×10^{-5}

Tabella 2: Schedule del learning rate.

Step	α
0 – 2 000 000	0.0
2 000 000 – 4 000 000	0.5
4 000 000 – 6 000 000	0.8

Tabella 3: Curriculum sugli scenari.

Parametro	Valore
Algoritmo	MaskablePPO
Policy	MlpPolicy (256×256, tanh)
Step totali	6 000 000
<i>n_steps</i>	4096
Batch size	128
Epoche	10
γ	0.99
λ (GAE)	0.95
Clip range	0.15
v_f coef	0.3
Ent. coef	0.01
Max grad norm	0.5
Target KL	0.01

Tabella 4: Iperparametri comuni ai tre training dell’ablation study.

5 Studio di Ablation della Funzione di Reward

5.1 Motivazione

È stato condotto uno studio di ablation per verificare l’effetto dei diversi componenti della funzione di reward sulle prestazioni dell’agente. L’obiettivo è determinare quali componenti siano effettivamente necessari e quali possano invece introdurre segnali di rinforzo fuorvianti.

5.2 Le Tre Varianti di Reward

Sono stati definiti tre modi di reward, configurabili tramite il parametro `reward_mode` nel file di configurazione. L’observation space (116 dimensioni) rimane identico in tutti e tre.

full — Reward Completa (modello di riferimento)

La reward function completa, utilizzata nel modello `ppo_20260513`:

- Bonus sorgente raggiunta: +100 (+ time bonus fino a +50)
- Penaltà uscita dal dominio: −10
- Reward distanza quadratica con zone multiplier e retreat asymmetry ($\times 3$)
- Reward gradiente di concentrazione: ± 0.05
- Reward allineamento vento: ± 0.05
- Reward allineamento corrente: ± 0.05
- Penaltà tempo: −0.1 per step
- Penaltà land proximity: fino a −15
- Stagnation penalty: −1.5 (finestra 15 step)

- Directional stagnation penalty: -0.5

base — Reward di Base

Versione semplificata: rimossi i componenti ad hoc (stagnation, zone multiplier, retreat asymmetry), distanza lineare al posto di quella quadratica. Wind e current alignment rimangono attivi.

- Bonus sorgente: $+100$ (+ time bonus)
- Penaltà uscita dominio: -10
- Reward distanza lineare: $(d_{t-1} - d_t) \times 100/3000$
- Reward gradiente concentrazione: ± 0.05
- Reward allineamento vento: ± 0.05
- Reward allineamento corrente: ± 0.05
- Penaltà tempo: -0.1 per step
- Penaltà land proximity: fino a -15

minimal — Reward Minima

Identica a **base**, con wind e current alignment rimossi dal reward. Le relative osservazioni rimangono nell'input della rete invariate.

- Bonus sorgente: $+100$ (+ time bonus)
- Penaltà uscita dominio: -10
- Reward distanza lineare: $(d_{t-1} - d_t) \times 100/3000$
- Reward gradiente concentrazione: ± 0.05
- Penaltà tempo: -0.1 per step
- Penaltà land proximity: fino a -15

5.3 Setup del Training Sequenziale

I modelli **base** e **minimal** sono stati addestrati sequenzialmente da zero, ciascuno per 6 000 000 step, con gli stessi iperparametri e lo stesso observation space del modello di riferimento **full**. Il training è stato avviato automaticamente dallo script `src/train_ppo.py` tramite la funzione `main_ablation()`, senza intervento manuale tra i due run.

Modello	Config	reward_mode
ppo_20260513_154951	config.yaml	full
ppo_20260516_095551	config_base.yaml	base
ppo_20260516_143937	config_base_no_wind.yaml	minimal

Tabella 5: Modelli addestrati nell'ablation study con relativa configurazione.

5.4 Risultati

L'inferenza è stata condotta sulle 26 sorgenti held-out (SRC107–SRC132), 3 chunk temporali (Q1/4, Q1/2, Q3/4), 4 scenari vento (V0–V3), 5 episodi per scenario — per un totale di **1560 episodi** per modello. La policy è stata valutata in modalità deterministica (anziché campionare dalla distribuzione di probabilità sulle azioni, viene selezionata direttamente l'azione con probabilità massima).

Metrica	base	full	minimal
SR globale	88,3%	95,6% (+7,3%)	96,9% (+8,6%)
Dist. iniziale media	799,9 m	802,1 m	801,1 m
Step medi (successo)	113,8 (~19,0 min)	129,6 (~21,6 min)	129,2 (~21,5 min)
V0	99,5%	98,0% (-1,5%)	100,0% (+0,5%)
V1	95,4%	99,0% (+3,6%)	99,0% (+3,6%)
V2	67,9%	88,5% (+20,6%)	88,7% (+20,8%)
V3	90,3%	97,0% (+6,7%)	99,7% (+9,4%)
Q1/4	100,0%	100,0% (0%)	100,0% (0%)
Q1/2	74,4%	93,7% (+19,3%)	93,5% (+19,1%)
Q3/4	90,4%	93,0% (+2,6%)	97,1% (+6,7%)

Tabella 6: Confronto delle prestazioni dei tre modelli su 1560 episodi ciascuno (26 sorgenti held-out, 4 venti, 3 chunk, 5 episodi). I delta di **full** sono vs **base**; i delta di **minimal** sono vs **base**.

5.5 Analisi dei Risultati

I grafici seguenti mostrano le distribuzioni di distanza iniziale, success rate, tempo al successo e distanza residua nel tempo per i modelli **base** e **minimal**, calcolati sui 1560 episodi di inferenza.

Modello base



Figura 1: Distribuzione delle distanze iniziali — **base**.




Figura 2: Success rate per scenario — base.




Figura 3: Distribuzione del tempo al successo — base.




Figura 4: Distanza media dalla sorgente nel tempo — base.

Modello minimal




Figura 5: Distribuzione delle distanze iniziali — minimal.




Figura 6: Success rate per scenario — minimal.




Figura 7: Distribuzione del tempo al successo — minimal.




Figura 8: Distanza media dalla sorgente nel tempo — **minimal**.

5.6 Conclusioni

Reward minima vs. reward completa

Il modello **minimal** ottiene un success rate del **96,9%**, superando sia il modello **full** (95,6%) che **base** (88,3%), con configurazione di training identica e stesso observation space. Questo risultato indica che i componenti aggiuntivi della reward **full** (stagnation penalty, zone multiplier, retreat asymmetry) non producono un guadagno misurabile rispetto a una reward lineare più semplice.

Effetto del wind/current alignment

Il delta più significativo è tra **base** e **minimal**: $-8,6\%$ di success rate globale, con un crollo di circa 20 punti percentuali su Q1/2 (74,4% vs 93,5%) e su V2 (67,9% vs 88,7%). I reward di allineamento vento e corrente (± 0.05 ciascuno) assumono che la sorgente si trovi sempre controvento/controcorrente rispetto all'agente. Questa ipotesi non è valida in un ambiente costiero complesso, dove riflessioni, correnti locali e morfologia della costa rendono il percorso ottimale non riducibile alla direzione del flusso. Il segnale risultante è in conflitto con il gradiente chimico in una frazione rilevante degli scenari, degradando la politica appresa.

Si osserva inoltre che i componenti aggiuntivi della reward **full** (stagnation, zone multiplier, retreat asymmetry) sembrano svolgere in parte il ruolo di compensare il segnale negativo introdotto dal wind/current alignment, portando il risultato finale a un livello comparabile con **minimal** nonostante la presenza dello stesso segnale fuorviante.

Ruolo del gradiente chimico

Il gradiente di concentrazione (± 0.05) è l'unico segnale direzionale nella reward **minimal**. Essendo calcolato direttamente sul campo di concentrazione simulato, incorpora implicitamente l'effetto di vento e corrente — poiché il plume si disperde seguendo questi flussi. L'agente non necessita di ricevere l'informazione sul vento nel reward se può già leggerla nella struttura spaziale del campo chimico.