

HYDRAS — Report v10

Studio di Ablation della Funzione di Reward

1 Algoritmo PPO

L'agente è addestrato con **MaskablePPO** (sb3-contrib), estensione di Proximal Policy Optimization che integra l'action masking per impedire collisioni con la costa. L'architettura della policy è una MLP con due reti separate (attore e critico), ciascuna composta da due strati nascosti da 256 neuroni con attivazione tanh. Il training utilizza **SubprocVecEnv** con 6 worker paralleli ($2 \text{ worker} \times 3 \text{ chunk}$) avviati con `start_method='fork'` per ridurre l'overhead di inizializzazione e raggiungere un throughput di circa 300 K step/ora.

2 Dataset — 132 Sorgenti $\times$ 4 Scenari Vento

2.1 Acquisizione e Gestione Dati

Il dataset è composto da simulazioni oceanografiche MIKE21 su un dominio marino di 3×2.5 km nella baia di Cecina (costa toscana, UTM32N), con risoluzione spaziale di 10 m e passo temporale di 10 s. Ogni sorgente è identificata da un codice univoco (SRC001–SRC132); per ciascuna sorgente sono disponibili 4 file di concentrazione corrispondenti ai 4 scenari di vento V0–V3.

2.2 I Quattro Scenari Vento (V0–V3)

I quattro scenari di vento sono caratterizzati da direzioni e intensità differenti, generando plume con morfologie diverse. Il modello viene valutato su tutti e 4 gli scenari per verificarne la robustezza rispetto alle condizioni ambientali.

2.3 Split Training / Inferenza

Il dataset è suddiviso in modo da garantire una valutazione su sorgenti mai viste durante il training:

- **Training:** SRC001–SRC106 (80%, 106 sorgenti)
- **Inferenza:** SRC107–SRC132 (20%, 26 sorgenti)

3 Ambiente di Simulazione

L'ambiente implementa l'interfaccia `gymnasium.Env` con spazio delle azioni discreto a 8 direzioni. Ogni episodio ha una durata massima di 1080 step (= 3 h di tempo simulato). Il dataset è suddiviso in 3 chunk temporali (Q1/4, Q1/2, Q3/4) per variare le condizioni iniziali del campo di concentrazione lungo l'asse temporale della simulazione.

3.1 Constraints di Spawn e Fallback Automatico

Lo spawn dell'agente viene campionato uniformemente nelle celle marine del dominio che soddisfano simultaneamente tre condizioni: (1) assenza di terra secondo la land mask, (2) distanza dalla costa ≥ 50 m, (3) concentrazione chimica $c \geq 0.5$. Se nessuna

cella soddisfa tutte e tre le condizioni, il threshold di concentrazione viene abbassato progressivamente fino a trovare una posizione valida (fallback automatico).

4 Training e Architettura

4.1 Input della Rete Neurale — 116 Dimensioni

L’observation space è composto da 116 dimensioni che forniscono all’agente una rappresentazione completa del campo chimico locale, della propria cinematica e delle condizioni ambientali (vento e corrente). Tutte le feature sono normalizzate nell’intervallo $[0, 1]$ o $[-1, 1]$.

Feature	Dim.	Descrizione
Concentrazione attuale	1	Concentrazione normalizzata nella posizione corrente
Memoria concentrazione	9	Ultime 9 letture di concentrazione
Gradienti spaziali	8	Gradiente di concentrazione nelle 8 direzioni
Posizione normalizzata	2	x, y nel dominio $[0, 1]^2$
Velocità agente	2	v_x, v_y normalizzati
Vento (componenti)	2	u_w, v_w normalizzati
Corrente (componenti)	2	u_c, v_c normalizzati
Memoria spostamenti	18	Ultimi 9 spostamenti (dx, dy)
Sensori direzionali	8	Concentrazione nelle 8 direzioni entro 20 m
Massima conc. osservata	3	Valore, posizione (x, y) del massimo storico
Step senza plume	1	Step dall’ultimo contatto con il plume (norm.)
Step totali	1	Progress episodio normalizzato
Distanza dalla costa	1	Distanza minima dalla costa normalizzata

Tabella 1: Input della rete neurale: 116 dimensioni totali.

4.2 Parametri di Training

I tre modelli dell’ablation study condividono gli stessi iperparametri; l’unica differenza tra le rispettive configurazioni è il parametro `reward_mode`.

4.3 Learning Rate Decrescente

Il learning rate segue uno schedule a gradini decrescenti: una fase iniziale ad alto learning rate favorisce l’esplorazione, mentre le fasi successive affinano la policy con aggiornamenti sempre più conservativi. Durante il training, la distribuzione degli scenari evolve progressivamente verso i casi più difficili tramite un parametro $\alpha \in [0, 1]$: per $\alpha = 0$ la distribuzione è uniforme, per $\alpha \rightarrow 1$ il peso è concentrato sugli scenari con vento più complesso (V2) e sui chunk temporali centrali.

Parametro	Valore
Algoritmo	MaskablePPO
Policy	MlpPolicy (256×256, tanh)
Step totali	6 000 000
n_steps	4096
Batch size	128
Epoche	10
γ	0.99
λ (GAE)	0.95
Clip range	0.15
v_f coef	0.3
Ent. coef	0.01
Max grad norm	0.5
Target KL	0.01

Tabella 2: Iperparametri comuni ai tre training dell’ablation study.

Step	LR
0 – 2 000 000	3×10^{-4}
2 000 000 – 4 000 000	1×10^{-4}
4 000 000 – 5 000 000	5×10^{-5}
5 000 000 – 6 000 000	1×10^{-5}

Tabella 3: Schedule del learning rate.

Step	α
0 – 2 000 000	0.0
2 000 000 – 4 000 000	0.5
4 000 000 – 6 000 000	0.8

Tabella 4: Curriculum sugli scenari.

5 Studio di Ablation della Funzione di Reward

5.1 Motivazione

È stato condotto uno studio di ablation per verificare l'effetto dei diversi componenti della funzione di reward sulle prestazioni dell'agente. L'obiettivo è determinare quali componenti siano effettivamente necessari e quali possano invece introdurre segnali di rinforzo fuorvianti.

5.2 Le Tre Varianti di Reward

Sono stati definiti tre modi di reward, configurabili tramite il parametro `reward_mode` nel file di configurazione. L'observation space (116 dimensioni) rimane identico in tutti e tre.

full — Reward Completa (modello di riferimento)

La reward function completa, utilizzata nel modello `ppo_20260513`:

- Bonus sorgente raggiunta: +100 (+ time bonus fino a +50)
- Penalità uscita dal dominio: -10
- Reward distanza quadratica con zone multiplier e retreat asymmetry ($\times 3$)
- Reward gradiente di concentrazione: ± 0.05
- Reward allineamento vento: ± 0.05
- Reward allineamento corrente: ± 0.05
- Penalità tempo: -0.1 per step
- Penalità land proximity: fino a -15
- Stagnation penalty: -1.5 (finestra 15 step)
- Directional stagnation penalty: -0.5

base — Reward di Base

Versione semplificata: rimossi i componenti ad hoc (stagnation, zone multiplier, retreat asymmetry), distanza lineare al posto di quella quadratica. Wind e current alignment rimangono attivi.

- Bonus sorgente: +100 (+ time bonus)
- Penalità uscita dominio: -10
- Reward distanza lineare: $(d_{t-1} - d_t) \times 100/3000$
- Reward gradiente concentrazione: ± 0.05
- Reward allineamento vento: ± 0.05
- Reward allineamento corrente: ± 0.05
- Penalità tempo: -0.1 per step

- Penalità land proximity: fino a -15

minimal — Reward Minima

Identica a **base**, con wind e current alignment rimossi dal reward. Le relative osservazioni rimangono nell'input della rete invariate.

- Bonus sorgente: $+100$ (+ time bonus)
- Penalità uscita dominio: -10
- Reward distanza lineare: $(d_{t-1} - d_t) \times 100/3000$
- Reward gradiente concentrazione: ± 0.05
- Penalità tempo: -0.1 per step
- Penalità land proximity: fino a -15

5.3 Setup del Training Sequenziale

I modelli **base** e **minimal** sono stati addestrati sequenzialmente da zero, ciascuno per 6 000 000 step, con gli stessi iperparametri e lo stesso observation space del modello di riferimento **full**. Il training è stato avviato automaticamente dallo script `src/train_ppo.py` tramite la funzione `main_ablation()`, senza intervento manuale tra i due run.

Modello	Config	reward_mode
ppo_20260513_154951	config.yaml	full
ppo_20260516_095551	config_base.yaml	base
ppo_20260516_143937	config_base_no_wind.yaml	minimal

Tabella 5: Modelli addestrati nell'ablation study con relativa configurazione.

5.4 Risultati

L'inferenza è stata condotta sulle 26 sorgenti held-out (SRC107–SRC132), 3 chunk temporali (Q1/4, Q1/2, Q3/4), 4 scenari vento (V0–V3), 5 episodi per scenario — per un totale di **1560 episodi** per modello. La policy è stata valutata in modalità deterministica.

5.5 Conclusioni

Reward minima vs. reward completa

Il modello **minimal** ottiene un success rate del **97%**, superando sia il modello **full** (96%) che **base** (88%), con configurazione di training identica e stesso observation space. Questo risultato indica che i componenti aggiuntivi della reward **full** (stagnation penalty, zone multiplier, retreat asymmetry) non producono un guadagno misurabile rispetto a una reward lineare più semplice.

Effetto del wind/current alignment

Il delta più significativo è tra **base** e **minimal**: -9% di success rate globale, con un crollo di circa 20 punti percentuali su Q1/2 e su V2. I reward di allineamento

Metrica	base	full	minimal
SR globale	88,3%	95,6% (+7,3%)	96,9% (+1,3%)
Dist. iniziale media	799,9 m	802,1 m	801,1 m
Step medi (successo)	113,8 (~19,0 min)	129,6 (~21,6 min)	129,2 (~21,5 min)
V0	99,5%	98,0% (-1,5%)	100,0% (+2,0%)
V1	95,4%	99,0% (+3,6%)	99,0% (0%)
V2	67,9%	88,5% (+20,6%)	88,7% (+0,2%)
V3	90,3%	97,0% (+6,7%)	99,7% (+2,7%)
Q1/4	100,0%	100,0% (0%)	100,0% (0%)
Q1/2	74,4%	93,7% (+19,3%)	93,5% (-0,2%)
Q3/4	90,4%	93,0% (+2,6%)	97,1% (+4,1%)

Tabella 6: Confronto delle prestazioni dei tre modelli su 1560 episodi ciascuno (26 sorgenti held-out, 4 venti, 3 chunk, 5 episodi). I delta sono calcolati rispetto alla colonna precedente.

vento e corrente (± 0.05 ciascuno) assumono che la sorgente si trovi sempre controvento/controcorrente rispetto all'agente. Questa ipotesi non è valida in un ambiente costiero complesso, dove riflessioni, correnti locali e morfologia della costa rendono il percorso ottimale non riducibile alla direzione del flusso. Il segnale risultante è in conflitto con il gradiente chimico in una frazione rilevante degli scenari, degradando la politica appresa.

Si osserva inoltre che i componenti aggiuntivi della reward **full** (stagnation, zone multiplier, retreat asymmetry) sembrano svolgere in parte il ruolo di compensare il segnale negativo introdotto dal wind/current alignment, portando il risultato finale a un livello comparabile con **minimal** nonostante la presenza dello stesso segnale fuorviante.

Ruolo del gradiente chimico

Il gradiente di concentrazione (± 0.05) è l'unico segnale direzionale nella reward **minimal**. Essendo calcolato direttamente sul campo di concentrazione simulato, incorpora implicitamente l'effetto di vento e corrente — poiché il plume si disperde seguendo questi flussi. L'agente non necessita di ricevere l'informazione sul vento nel reward se può già leggerla nella struttura spaziale del campo chimico.

Osservazioni sulla reward engineering

I risultati suggeriscono un principio generale per questo tipo di problema: **un observation space ricco rende il reward shaping complesso ridondante**. I componenti aggiuntivi del modello **full** erano stati introdotti iterativamente per correggere failure mode osservati con versioni precedenti dell'observation space. Con 116 dimensioni di osservazione — in particolare il gradiente chimico direzionale, la memoria degli spo-

stamenti e la storia della concentrazione — l'agente dispone di informazioni sufficienti per navigare efficacemente senza spinte esplicite aggiuntive nel reward.