

HYDRAS — Report V12

FCM Adattivo, RL con Doppia Corona di Sensori, Spawn Maps

1 FCM Adattivo con Passo Ottimizzato

1.1 Motivazione

Nel Field Climbing Method classico (FCM puro) il passo dell'agente è fisso: $\Delta x = v_{\max} \cdot \Delta t = 1 \text{ m/s} \times 10 \text{ s} = 10 \text{ m}$. Questa scelta è indipendente dall'intensità del gradiente stimato: in zone a gradiente debole il passo rimane invariato, portando a movimenti incerti e potenzialmente oscillanti; in zone a gradiente forte un passo fisso può sovrastimare la scala spaziale rilevante.

L'idea del FCM adattivo è di modulare il passo in proporzione inversa alla norma del gradiente stimato $\|\hat{\nabla}C\|$, interpretando quest'ultima come una misura della “certezza” locale della direzione di salita.

1.2 Passo Adattivo

Il FCM adattivo usa la seguente regola di passo:

$$\Delta x = \min\left(\frac{K}{\|\hat{\nabla}C\|}, \Delta x_{\max}\right) \quad (1)$$

dove:

- $K > 0$ è la **costante di proporzionalità** da ottimizzare;
- $\Delta x_{\max} = 50 \text{ m}$ è il cap superiore che evita passi eccessivi in zone a gradiente quasi nullo;
- $\|\hat{\nabla}C\|$ è la norma euclidea del gradiente stimato tramite regressione ai minimi quadrati (Taylor al primo ordine, 8 direzioni).

Il passo è inversamente proporzionale all'intensità del gradiente con costante K : vicino a un massimo (gradiente forte) l'agente avanza con cautela; in zone di plume diffuso (gradiente debole) avanza più rapidamente, con un cap superiore per evitare passi fuori scala.

1.3 Ottimizzazione di K tramite Metodo di Brent

La scelta di K è formulata come un problema di ottimizzazione scalare: si massimizza il success rate globale (SR) come funzione di K su un sottoinsieme di scenari di calibrazione:

$$K^* = \underset{K \in [K_{\min}, K_{\max}]}{\operatorname{argmax}} \text{ SR}(K) \quad (2)$$

Poiché SR è una funzione costosa da valutare (richiede la simulazione di tutti gli episodi) e non è garantita una forma analitica, si minimizza $f(K) = -\text{SR}(K)$ tramite il **metodo di Brent** (`scipy.optimize.brent`), un algoritmo di minimizzazione scalare a convergenza super-lineare che alterna interpolazione parabolica (veloce) e sezione

aurea (robusta). Il metodo mantiene un *bracket* $[a, b]$ garantito contenere il minimo e tre punti di riferimento: K (migliore), K_w (secondo migliore), K_v (precedente K_w). Ad ogni iterazione tenta l'interpolazione parabolica; se il punto suggerito cade fuori dal bracket o non riduce sufficientemente l'intervallo, retrocede alla sezione aurea. Converge in poche decine di valutazioni di f . Di seguito ne viene riportato lo pseudocodice.

Metodo di Brent: minimizzazione di $f(K)$ su $[a, b]$

$$\varphi = \frac{3 - \sqrt{5}}{2}; \quad (\text{sezione aurea} \approx 0,382)$$

ε, δ = tolleranze in input;

$$K = K_w = K_v = a + \varphi(b - a); \quad f_K = f_{K_w} = f_{K_v} = f(K);$$

$e = 0$; (ampiezza del passo precedente; 0 = nessun passo ancora eseguito)

finché $(b - a) > \varepsilon$:

$$m = \frac{a + b}{2};$$

se $|e| > \delta$: (tenta interpolazione parabolica)

$$r = (K - K_w)(f_K - f_{K_v});$$

$$q = (K - K_v)(f_K - f_{K_w});$$

$$p = (K - K_v) \cdot q - (K - K_w) \cdot r; \quad q = 2(q - r);$$

se $q > 0$: $p = -p$ **altrimenti**: $q = -q$; (garantisce $q > 0$)

$$\text{se } a < K + \frac{p}{q} < b \text{ e } \left| \frac{p}{q} \right| < \frac{|e|}{2}:$$

$$u = K + \frac{p}{q}; \quad (\text{accetta passo parabolico})$$

altrimenti:

$$e = (K \geq m ? a : b) - K; \quad u = K + \varphi \cdot e; \quad (\text{sezione aurea})$$

altrimenti:

$$e = (K \geq m ? a : b) - K; \quad u = K + \varphi \cdot e;$$

$$f_u = f(u);$$

se $f_u \leq f_K$: (aggiorna bracket e punti di riferimento)

se $u < K$: $b = K$; **altrimenti**: $a = K$;

$$K_v = K_w; \quad f_{K_v} = f_{K_w}; \quad K_w = K; \quad f_{K_w} = f_K; \quad K = u; \quad f_K = f_u;$$

altrimenti:

se $u < K$: $a = u$; **altrimenti**: $b = u$;

se $f_u \leq f_{K_w}$ **o** $K_w = K$:

$$K_v = K_w; \quad f_{K_v} = f_{K_w}; \quad K_w = u; \quad f_{K_w} = f_u;$$

altrimenti se $f_u \leq f_{K_v}$ **o** $K_v = K$ **o** $K_v = K_w$:

$$K_v = u; \quad f_{K_v} = f_u;$$

ritorna K ;

Il valore ottimo trovato è:

$$K^* = 0,124 \quad (3)$$

con cap $\Delta x_{\max} = 50$ m e sensor range $r_s = 50$ m (il valore ottimale dello sweep precedente).

1.4 Confronto FCM Puro vs. FCM Adattivo

Metrica	FCM Puro ($r_s=50$ m)	FCM Adattivo ($K^*=0,124$)
SR globale	32,9%	56,1% (+23,2%)
Step medi (succ.)	182,7 ($\sim 30,5$ min)	157,2 ($\sim 26,2$ min)
V0	39,7%	71,2% (+31,5%)
V1	16,0%	28,2% (+12,2%)
V2	23,7%	34,6% (+10,9%)
V3	51,9%	90,4% (+38,5%)
Q1/4	50,5%	84,1% (+33,6%)
Q1/2	11,5%	33,7% (+22,2%)
Q3/4	36,5%	50,5% (+14,0%)

Tabella 1: Confronto tra FCM puro (passo fisso 10 m) e FCM adattivo ($\Delta x = \min(K^*/\|\hat{\nabla}C\|, 50$ m)). Stesse 624 prove, sensor range $r_s = 50$ m, sorgenti SRC107–SRC132.

Il FCM adattivo porta un guadagno netto di **+23,2 punti percentuali** sul success rate globale e riduce il tempo medio al successo di circa 4 minuti simulati. Il miglioramento è particolarmente marcato per V3 (+38,5%) e Q1/4 (+33,6%), scenari in cui il plume è relativamente compatto e il gradiente più informativo. Nonostante ciò, le prestazioni rimangono nettamente inferiori a quelle del modello RL (96,9%), a conferma che la modulazione del passo non supplisce alla mancanza di memoria storica e di informazioni contestuali (vento, correnti).

2 RL con Doppia Corona di Sensori

2.1 Motivazione

Il modello RL precedente (“minimal”, 96,9% SR) equipaggiava l’agente con una singola corona di 8 sensori direzionali a $r_s = 20$ m. L’ipotesi alla base dell’estensione è che una **seconda corona a raggio maggiore** ($r_{s2} = 50$ m) fornisca all’agente informazioni sullo stato del plume a una scala spaziale più larga, complementare a quella locale.

2.2 Architettura dell’Osservazione

Lo spazio di osservazione passa da **116 dimensioni** (singola corona) a **196 dimensioni** (doppia corona), secondo la seguente struttura:

Componente	Singola corona	Doppia corona
Concentrazione corrente	1	1
Memoria concentrazione (9 step)	9	9
Memoria conc. Δ (9 step)	18	18
Sensori direz. corona 1 (8 dir.)	8	8
Sensori direz. corona 2 (8 dir.)	–	8
Memoria storica corona 1 (9×8)	72	72
Memoria storica corona 2 (9×8)	–	72
Velocità vento (2D)	2	2
Corrente marina (2D)	2	2
Informazione posizionale (4)	4	4
Totale	116	196

Tabella 2: Confronto tra lo spazio di osservazione a singola e doppia corona di sensori.

La doppia corona è implementata come estensione opzionale nell’ambiente: il parametro `sensor_range_2` (default `None`) abilita la seconda corona e ridimensiona automaticamente lo spazio di osservazione. In questo modo il codice rimane retrocompatibile con i modelli a singola corona (116-dim) già addestrati.

2.3 Confronto RL Minimal vs. RL Doppia Corona

Metrica	RL Minimal (116-dim)	RL Doppia Corona (196-dim)
SR globale	96,9%	93,0% (−3,9%)
Step medi (succ.)	129,2 (~21,5 min)	114,4 (~19,1 min)
V0	100,0%	99,7% (−0,3%)
V1	99,0%	90,3% (−8,7%)
V2	88,7%	82,3% (−6,4%)
V3	99,7%	99,7% 0,0%
Q1/4	100,0%	100,0% 0,0%
Q1/2	93,5%	86,2% (−7,3%)
Q3/4	97,1%	92,9% (−4,2%)

Tabella 3: Confronto tra il modello RL minimal (ppo_20260516_143937, 1560 episodi) e il modello RL con doppia corona (ppo_20260529_214839, 1560 episodi). In verde il valore migliore per ogni riga.

2.4 Discussione

Il modello a doppia corona non supera il modello minimal: il success rate globale diminuisce di 3,9 punti percentuali ($96,9\% \rightarrow 93,0\%$), con regressioni concentrate su V1 ($-8,7\%$), V2 ($-6,4\%$) e Q1/2 ($-7,3\%$). La contrazione del tempo medio al successo ($-2,4\text{ min}$) suggerisce che nei casi in cui l'agente converge, lo fa più rapidamente; tuttavia la riduzione del SR indica che la seconda corona introduce rumore nel processo decisionale per alcuni scenari.

La spiegazione più plausibile è che l'informazione proveniente dalla corona a 50 m, troppo distante in condizioni di plume diffuso o turbolento (V1, V2, Q1/2), distoglie l'agente dalla concentrazione locale più affidabile. Questo risultato indica che, per questo dominio e questa configurazione di reward, la singola corona a 20 m è sufficiente e la doppia corona non porta benefici netti.

3 Spawn Maps: Analisi dei Punti di Partenza

3.1 Metodologia

Per le combinazioni vento-chunk (v, q) con success rate medio inferiore al 100%, è stata generata una **mappa degli spawn point** per identificare eventuali zone spaziali sistematicamente critiche.

La procedura è la seguente:

1. Si identificano le combinazioni attive (v, q) in cui almeno un episodio (su 1560 totali) è risultato in fallimento.
2. Per ogni combinazione attiva, si contano i fallimenti per sorgente e si selezionano le **5 sorgenti** con il maggior numero di fallimenti complessivi.
3. Per ogni terna (sorgente, v, q), si eseguono 10 episodi con il modello minimal e si registrano le coordinate di spawn $\mathbf{p}_0$.
4. Ogni punto di spawn viene contrassegnato con:
 - **● cerchio verde** se l'episodio è terminato con successo;
 - **✗ croce rossa** se l'episodio è terminato con fallimento.
5. Il background di ogni subplot mostra la distribuzione del plume di concentrazione all'istante $t = Q^*$ (Q1/4, Q1/2 o Q3/4 della simulazione) per quella specifica sorgente, garantendo che gli spawn point siano all'interno del plume corretto.

3.2 Risultati

Le mappe seguenti mostrano una figura per ciascuna delle 5 sorgenti selezionate. Ogni figura contiene un subplot per ogni combinazione (v, q) attiva.

Spawn map SRC114




Figura 1: Spawn map — SRC114. Punti di partenza per ogni combinazione vento/chunk attiva.

Spawn map SRC115




Figura 2: Spawn map — SRC115.

Spawn map SRC119




Figura 3: Spawn map — SRC119.

Spawn map SRC120




Figura 4: Spawn map — SRC120.

Spawn map SRC132




Figura 5: Spawn map — SRC132.

3.3 Conclusione

In tutte e cinque le sorgenti analizzate, i punti di partenza che portano al successo e quelli che portano al fallimento **non mostrano alcuna separazione spaziale**: non emergono zone di spawn sistematicamente “difficili” o “facili”. Questo indica che l’esito di un episodio non dipende dalla posizione iniziale dell’agente, bensì dalle condizioni idrodinamiche locali (intensità e direzione del plume, turbolenza) proprie di quel chunk temporale e di quello scenario di vento. I fallimenti residui del modello minimal sono pertanto da attribuire a caratteristiche intrinseche degli scenari più difficili (V2, Q1/2) piuttosto che a limitazioni geometriche dello spazio di spawn.