

HYDRAS — Report V12

FCM Adattivo, RL con Doppia Corona di Sensori, Spawn Maps

1 FCM Adattivo con Adam

1.1 Motivazione

Nel Field Climbing Method classico (FCM puro) il passo dell'agente è fisso: $\Delta x = v_{\max} \cdot \Delta t = 1 \text{ m/s} \times 10 \text{ s} = 10 \text{ m}$. Questa scelta è indipendente dalla storia del gradiente: l'agente reagisce solo alla lettura corrente dei sensori, senza memoria delle direzioni percorse negli step precedenti. In un ambiente con segnale rumoroso o plume diffuso, questo porta a traiettorie oscillanti e convergenza lenta.

Il FCM adattivo sostituisce la regola di passo fisso con l'ottimizzatore **Adam**, che accumula un momentum sul gradiente stimato e normalizza il passo per la varianza storica, ottenendo un comportamento più robusto al rumore e più direzionato.

1.2 FCM con Adam

Ad ogni timestep t , l'agente stima il gradiente locale $\hat{\nabla}C \in \mathbb{R}^2$ tramite regressione ai minimi quadrati (Taylor al primo ordine, 8 sensori direzionali a $r_s = 50 \text{ m}$). Il vettore di passo viene calcolato con la regola di aggiornamento Adam:

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \hat{\nabla}C_t \quad (1)$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) \hat{\nabla}C_t^2 \quad (2)$$

$$\hat{\mathbf{m}}_t = \frac{\mathbf{m}_t}{1 - \beta_1^t}, \quad \hat{\mathbf{v}}_t = \frac{\mathbf{v}_t}{1 - \beta_2^t} \quad (3)$$

$$\mathbf{s}_t = lr \cdot \frac{\hat{\mathbf{m}}_t}{\sqrt{\hat{\mathbf{v}}_t} + \varepsilon} \quad (4)$$

dove $\mathbf{m}_t, \mathbf{v}_t \in \mathbb{R}^2$ sono rispettivamente il primo e il secondo momento del gradiente (inizializzati a $\mathbf{0}$ all'inizio di ogni episodio), $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\varepsilon = 10^{-8}$, e lr è il *learning rate* (passo base in metri).

Il passo fisico effettivo è cappato a $\Delta x_{\max} = 50 \text{ m}$:

$$\Delta x_t = \min(\|\mathbf{s}_t\|, \Delta x_{\max}) \quad (5)$$

L'azione discreta viene scelta come la direzione $\hat{d}_i$ più allineata al vettore $\mathbf{s}_t$:

$$a_t = \operatorname{argmax}_{i \in \{1, \dots, 8\}} \hat{d}_i \cdot \mathbf{s}_t \quad (6)$$

Il momentum (β_1) mantiene la direzione coerente su più timestep, smorzando le oscillazioni dovute al rumore del sensore. La normalizzazione per $\sqrt{\hat{\mathbf{v}}_t}$ riduce il passo nelle direzioni in cui il gradiente è inconsistente nel tempo.

1.3 Pseudocodice

FCM Adam: aggiornamento del passo per ogni timestep dell'episodio

— Inizio episodio —

$\mathbf{m} = \mathbf{0}_2$; $\mathbf{v} = \mathbf{0}_2$; $t = 0$;

— Per ogni timestep —

$\hat{\nabla}C = \text{stima_gradiente}(\text{obs})$; (*minimi quadrati, 8 sensori*)

$t = t + 1$;

$\mathbf{m} = \beta_1 \cdot \mathbf{m} + (1 - \beta_1) \cdot \hat{\nabla}C$;

$\mathbf{v} = \beta_2 \cdot \mathbf{v} + (1 - \beta_2) \cdot \hat{\nabla}C^2$;

$\hat{\mathbf{m}} = \mathbf{m} / (1 - \beta_1^t)$; $\hat{\mathbf{v}} = \mathbf{v} / (1 - \beta_2^t)$;

$\mathbf{s} = lr \cdot \hat{\mathbf{m}} / (\sqrt{\hat{\mathbf{v}}} + \varepsilon)$;

$\Delta x = \min(\|\mathbf{s}\|, \Delta x_{\max})$;

$a = \text{argmax}_i (\hat{d}_i \cdot \mathbf{s})$;

1.4 Sweep su lr e Confronto con FCM Puro

Il parametro lr è stato ottimizzato tramite sweep su $lr \in \{10, 20, 30, 40, 50\}$ m, con 624 episodi per valore (26 sorgenti $\times$ 4 versioni $\times$ 3 chunk $\times$ 2 ep), sensor range $r_s = 50$ m.

lr	SR%	Step medi	V0	V1	V2	V3	Q1/4	Q1/2	Q3/4
FCM puro	32,9	182,7	39,7	16,0	23,7	51,9	50,5	11,5	36,5
10 m	49,8	143,4	67,9	25,0	28,2	78,2	73,1	28,4	48,1
20 m	55,1	120,7	73,7	28,8	31,4	86,5	80,3	35,6	49,5
30 m	58,2	107,0	76,9	31,4	34,6	89,7	85,1	38,5	51,0
40 m	59,1	87,7	80,1	30,8	32,7	92,9	84,1	42,3	51,0
50 m	60,9	80,6	82,7	29,5	35,9	95,5	88,9	42,8	51,0

Tabella 1: Sweep su lr per FCM Adam ($\beta_1=0,9$, $\beta_2=0,999$, $\Delta x_{\max}=50$ m, $r_s=50$ m, 624 episodi per valore). In verde il valore ottimale $lr=50$ m.

Il FCM Adam con $lr = 50$ m raggiunge un success rate globale del **60,9%**, con un guadagno di **+28,0 punti percentuali** rispetto al FCM puro (32,9%). All'aumentare di lr si osserva una tendenza monotona sia nel SR che negli step medi al successo (da 143 a 80 step): passi più ampi riducono il numero di timestep necessari per raggiungere la sorgente. Il miglioramento è consistente su tutti gli scenari, con V3 e Q1/4 che beneficiano maggiormente del momentum. Nonostante ciò, le prestazioni rimangono

nettamente inferiori a quelle del modello RL (96,9%), a conferma che il momentum sul gradiente locale non supplisce alla mancanza di memoria globale dell'episodio e di informazioni contestuali (vento, correnti).

1.5 Analisi dei Risultati — $lr = 50$ m




Figura 1: Success rate per scenario di vento e chunk temporale — FCM Adam $lr=50$ m.




Figura 2: Distribuzione del tempo al successo — FCM Adam $lr=50$ m.




Figura 3: Distanza media dalla sorgente nel tempo — FCM Adam $lr=50$ m.

2 RL con Doppia Corona di Sensori

2.1 Motivazione

Il modello RL precedente (“minimal”, 96,9% SR) equipaggiava l’agente con una singola corona di 8 sensori direzionali a $r_s = 20$ m. L’ipotesi alla base dell’estensione è che una **seconda corona a raggio maggiore** ($r_{s2} = 50$ m) fornisca all’agente informazioni sullo stato del plume a una scala spaziale più larga, complementare a quella locale.

2.2 Architettura dell’Osservazione

Lo spazio di osservazione passa da **116 dimensioni** (singola corona) a **196 dimensioni** (doppia corona), secondo la seguente struttura:

Componente	Singola corona	Doppia corona
Concentrazione corrente	1	1
Memoria concentrazione (9 step)	9	9
Memoria conc. Δ (9 step)	18	18
Sensori direz. corona 1 (8 dir.)	8	8
Sensori direz. corona 2 (8 dir.)	—	8
Memoria storica corona 1 (9×8)	72	72
Memoria storica corona 2 (9×8)	—	72
Velocità vento (2D)	2	2
Corrente marina (2D)	2	2
Informazione posizionale (4)	4	4
Totale	116	196

Tabella 2: Confronto tra lo spazio di osservazione a singola e doppia corona di sensori.

La doppia corona è implementata come estensione opzionale nell’ambiente: il parametro `sensor_range_2` (default `None`) abilita la seconda corona e ridimensiona automaticamente lo spazio di osservazione. In questo modo il codice rimane retrocompatibile con i modelli a singola corona (116-dim) già addestrati.

2.3 Confronto RL Minimal vs. RL Doppia Corona

Metrica	RL Minimal (116-dim)	RL Doppia Corona (196-dim)
SR globale	96,9%	93,0% (−3,9%)
Step medi (succ.)	129,2 (~21,5 min)	114,4 (~19,1 min)
V0	100,0%	99,7% (−0,3%)
V1	99,0%	90,3% (−8,7%)
V2	88,7%	82,3% (−6,4%)
V3	99,7%	99,7% 0,0%
Q1/4	100,0%	100,0% 0,0%
Q1/2	93,5%	86,2% (−7,3%)
Q3/4	97,1%	92,9% (−4,2%)

Tabella 3: Confronto tra il modello RL minimal (ppo_20260516_143937, 1560 episodi) e il modello RL con doppia corona (ppo_20260529_214839, 1560 episodi). In verde il valore migliore per ogni riga.

2.4 Discussione

Il modello a doppia corona non supera il modello minimal: il success rate globale diminuisce di 3,9 punti percentuali (96,9% → 93,0%), con regressioni concentrate su V1 (−8,7%), V2 (−6,4%) e Q1/2 (−7,3%). La contrazione del tempo medio al successo (−2,4 min) suggerisce che nei casi in cui l’agente converge, lo fa più rapidamente; tuttavia la riduzione del SR indica che la seconda corona introduce rumore nel processo decisionale per alcuni scenari.

La spiegazione più plausibile è che l’informazione proveniente dalla corona a 50 m, troppo distante in condizioni di plume diffuso o turbolento (V1, V2, Q1/2), distoglie l’agente dalla concentrazione locale più affidabile. Questo risultato indica che, per questo dominio e questa configurazione di reward, la singola corona a 20 m è sufficiente e la doppia corona non porta benefici netti.

3 Spawn Maps: Analisi dei Punti di Partenza

3.1 Metodologia

Per le combinazioni vento–chunk (v , q) con success rate medio inferiore al 100%, è stata generata una **mappa degli spawn point** per identificare eventuali zone spaziali sistematicamente critiche.

La procedura è la seguente:

1. Si identificano le combinazioni attive (v, q) in cui almeno un episodio (su 1560 totali) è risultato in fallimento.
2. Per ogni combinazione attiva, si contano i fallimenti per sorgente e si selezionano le **5 sorgenti** con il maggior numero di fallimenti complessivi.
3. Per ogni terna (sorgente, v , q), si eseguono 10 episodi con il modello minimal e si registrano le coordinate di spawn $\mathbf{p}_0$.
4. Ogni punto di spawn viene contrassegnato con:
 - • **cerchio verde** se l'episodio è terminato con successo;
 - × **croce rossa** se l'episodio è terminato con fallimento.
5. Il background di ogni subplot mostra la distribuzione del plume di concentrazione all'istante $t = Q^*$ ($Q1/4$, $Q1/2$ o $Q3/4$ della simulazione) per quella specifica sorgente, garantendo che gli spawn point siano all'interno del plume corretto.

3.2 Risultati

Le mappe seguenti mostrano una figura per ciascuna delle 5 sorgenti selezionate. Ogni figura contiene un subplot per ogni combinazione (v, q) attiva.

Spawn map SRC114




Figura 4: Spawn map — SRC114. Punti di partenza per ogni combinazione vento/chunk attiva.

Spawn map SRC115




Figura 5: Spawn map — SRC115.

Spawn map SRC119




Figura 6: Spawn map — SRC119.

Spawn map SRC120




Figura 7: Spawn map — SRC120.

Spawn map SRC132




Figura 8: Spawn map — SRC132.

3.3 Conclusione

In tutte e cinque le sorgenti analizzate, i punti di partenza che portano al successo e quelli che portano al fallimento **non mostrano alcuna separazione spaziale**: non emergono zone di spawn sistematicamente “difficili” o “facili”. Questo indica che l’esito di un episodio non dipende dalla posizione iniziale dell’agente, bensì dalle condizioni idrodinamiche locali (intensità e direzione del plume, turbolenza) proprie di quel chunk temporale e di quello scenario di vento. I fallimenti residui del modello minimal sono pertanto da attribuire a caratteristiche intrinseche degli scenari più difficili (V2, Q1/2) piuttosto che a limitazioni geometriche dello spazio di spawn.